


УЧЕБНО-МЕТОДИЧЕСКИЕ МАТЕРИАЛЫ «ПОДГОТОВКА ДАННЫХ И ПЕРВИЧНЫЙ ГРАФИЧЕСКИЙ АНАЛИЗ ДАННЫХ»

Качественная информация приводит к правильным решениям, сама же она существенно выигрывает от грамотной обработки. Поэтому для современного человека необходимо умение получать, представлять, анализировать и интерпретировать полученную информацию.



1. Ввод данных, виды переменных, табличное представление данных

Сбор данных, или наблюдение, – первый этап любого статистического исследования. Первичные статистические данные являются основой для всей дальнейшей работы.

Прежде чем собирать данные, нужно продумать, для чего эти данные необходимы, какова цель исследования. Именно целью определяется характер собираемых сведений и их количество.

Если при сборе данных допущена ошибка, материал оказался некачественным, это повлияет на правильность и достоверность выводов. Поэтому этап сбора данных необходимо продумать и организовать.

Когда данные собраны, для их анализа используются различные статистические методы, предназначенные для превращения данных в источник информации. Важно в процессе сбора упорядочить данные, чтобы облегчить их дальнейшую обработку.

В современных универсальных статистических программах данные вводятся как наборы значений переменных, соответствующих определенному событию. Названия переменных – заголовки столбцов, наблюдения – строки.

Например, регистрация событий «заказ» может выглядеть так

№	дата	компания	код товара	кол-во, шт.	сумма, руб.	агент	скидка, %	
1	12.03.19	Дом	гн12	1000	30564	Петрова	5	
2	12.03.19	Стройсервис	шш223	500	86543	Сидорова	1,5	

Регистрация событий «аварийный простой оборудования»

№	дата	агрегат	узел	продолжительность простоя, час.	работа после ремонта, час.	последний осмотр		
1	12.03.19	ДМ	гн12	12	368	Петров		
2	15.03.19	СС	шш223	5	124	Сидоров		

Регистрация событий «анонимная анкета уволившегося сотрудника»

№	дата	возраст, лет	пол	специальность	образование	сколько проработали, лет	причина	
1	12.03.19	29	м	слесарь 5 разряда	средне-спец.	7	низкая з/п	
2	15.03.19	35	ж	нормировщик	среднее	1	конфликт с руководителем	

Типы переменных

Одна из первых задач работы с данными – определить тип переменных, которые регистрируются в наблюдениях.

Знание типа переменной определяет круг разрешенных методов обработки.

Переменные бывают **количественные** и **категориальные**.

Количественные переменные позволяют численно выразить и сравнить различия между наблюдениями. Например, измерения физических величин (времени, пространства, веса, и т.д.) и экономических величин (доходы, расходы, прибыль и т.д.).

Количественные переменные в свою очередь могут быть:

- **непрерывные** – те, которые при необходимости могут быть измерены по сколь угодно мелким шкалам. Например, продолжительность телефонного разговора, вес детали.

- **дискретные** – те, которые принимают какие-то установленные значения (часто целые числа). Например, число телефонных звонков за день, число сотрудников в штате компании, количество бракованных изделий в партии.

Непрерывные переменные легко сделать дискретными. Например, возраст человека округляется до числа полных лет.

Категориальные переменные используются для качественной классификации наблюдений, например: профессия, компания, марка автомобиля, тип дефекта и т.д. Иногда категориальная переменная позволяет ранжировать (упорядочить) наблюдения, указав какие из них в большей или меньшей степени обладают данным качеством. Например, квалификация токарь 5 разряда выше, чем квалификация токарь 4 разряда. Однако нельзя сказать "насколько больше" или "насколько меньше".

Количественные переменные переводятся в категориальные путем установки интервалов для каждого значения категориальной переменной. Например, объем грудной клетки становится размером одежды S, M, L, XL, XXL.

При необходимости категориальные переменные переводятся в количественные при помощи искусственных шкал. Обычные школьные отметки – «отлично»-5, «хорошо»-4 – пример такого перевода. Нужно быть осторожным при интерпретации результатов обработки таких искусственных количественных переменных.

СВОДНЫЕ ТАБЛИЦЫ

Первая стадия преобразования сырых данных в полезную информацию – сведение их в таблицы и представление в структурированном виде. Чтобы проиллюстрировать этот процесс, рассмотрим опрос, проводившийся для изучения жилищных условий студентов университета. В этом простом исследовании нескольких случайно выбранных студентов спросили об их возрасте, поле, условиях проживания и ежемесячных расходах на жилье. Было опрошено 36 студентов.

Таблица 1

Исходные данные студенческого анкетного опроса

№ п/п	Пол	Возраст	Тип жилищных условий	Расходы на жилье, \$
1	М	18	Арендует комнату	125
2	М	20	Арендует квартиру	130
3	Ж	18	Собственное жилье	120
4	Ж	19	Общежитие	128
5	Ж	18	Общежитие	137
6	Ж	21	Арендует квартиру	141
7	М	25	Собственное жилье	162
8	Ж	18	Арендует комнату	153
9	М	18	Общежитие	136
10	М	18	Общежитие	143
11	Ж	19	Арендует квартиру	129
12	М	18	Арендует квартиру	138
13	М	19	Арендует квартиру	135
14	М	19	Арендует квартиру	141
15	Ж	20	Общежитие	152
16	Ж	18	Арендует комнату	140
17	Ж	20	Арендует комнату	133
18	М	21	Арендует комнату	129
19	М	18	Арендует квартиру	157
20	М	18	Автофургон	100
21	Ж	19	Арендует квартиру	146
22	М	19	Арендует квартиру	135
23	Ж	18	Общежитие	115
24	Ж	18	Общежитие	110
25	М	20	Собственное жилье	134
26	Ж	20	Общежитие	127

27	М	18	Общежитие	132
28	Ж	18	Арендует квартиру	135
29	Ж	20	Арендует комнату	126
30	Ж	28	Собственное жилье	110
31	М	18	Собственное жилье	112
32	М	19	Арендует квартиру	130
33	Ж	21	Арендует комнату	140
34	М	23	Общежитие	135
34	Ж	18	Гостиница	145
36	М	20	Арендует комнату	132

Необработанные исходные данные не особенно полезны, и чтобы увеличить их ценность необходимо сделать какие-то обобщения в виде сводных таблиц и графиков.

Пол студентов - это категориальная переменная. Переменная принимает 2 значения: «мужчина» и «женщина», данные классифицируются весьма просто. Подсчет числа лиц каждого пола дает частоту появления для каждой категории.

Таблица 1а

Пол студентов	
Пол	Число студентов
М	18
Ж	18
Всего	36

Если бы в опросе участвовало не 36, а 360 студентов, то было бы удобно использовать функцию ЧАСТОТА в программе Excel.

Возраст студентов – это количественная дискретная переменная. Переменная принимает значения от 18 (min) до 28 (max). Студент определяет свой возраст как дискретную, а не непрерывную величину. Он укажет, что ему 21 год, даже если 22 года ему исполнится завтра. По математическим правилам округления через шесть месяцев после дня рождения его возраст ближе к 22, но в анкетах это не учитывается.

Таблица 1б

Возраст студентов	
Возраст	Число студентов
18	16
19	7
20	7
21	3
22 и больше	3
Всего	36

Тип жилищных условий – это категориальная переменная. Переменная принимает 6 значений. В правом столбце приводится частота появления каждого из значений. Два значения, встретившиеся в данных по одному разу, объединены в одно.

Таблица 1в

Тип жилищных условий	
Тип жилищных условий	Число студентов
Общежитие	10
Арендует квартиру	11
Собственное жилье	5
Арендует комнату	8
Другое	2
Всего	36

Ежемесячные расходы на жилье – это количественная непрерывная переменная. Максимальное значение расходов на жилье 162 \$, минимальное – 100 \$, можно выбрать ширину интервала 10 и начинать группировать от значения 90. Крайние точки интервалов тогда будут 100, 110, 120 и т.д. Нужно отметить, что группирование непрерывных данных приводит к потере некоторой информации.

Проведем рутинную ручную работу и одно за другим разнесем значения расходов на жилье по интервалам. Пересчитав рабочие пометки, определим, сколько данных попадает в каждый интервал.

Таблица 1г

Ежемесячные расходы на жилье			
Ежемесячные расходы на жилье, \$	$\frac{1}{2}$ интервала	Рабочие пометки	Частота
91 - 100	95	I	1
101 - 110	105	II	2
111 - 120	115	III	3
121 - 130	125	### III	8
131 - 140	135	### ### III	13
141 - 150	145	###	5
151 - 160	155	III	3
161 - 170	165	I	1
Всего		36	36

Чаще всего студенты тратят от \$131 до \$140. И, конечно, есть способ делать такие расчеты не вручную.

1.3 СЛОЖНЫЕ СВОДНЫЕ ТАБЛИЦЫ

Часто нужно конструировать таблицы, которые включают более одной переменной. Например, таблица, показывающая количество мужчин и женщин в каждой возрастной категории.

Таблица 1д

Возраст и пол студентов			
Возраст	Число студентов		
	Мужчина	Женщина	Всего
18	8	8	16
19	4	3	7
20	3	4	7
21	1	2	3
22 и более	2	1	3
Всего	18	18	36

Сложные сводные таблицы легко делать в программе Excel. Но не стоит злоупотреблять усложнением таблиц. Чем больше информации содержится в таблице, тем труднее ее понимать.

Рекомендации по созданию хорошей таблицы:

- если данных много, то две-три простые таблицы лучше, чем одна сложная;
- каждой таблице дайте название;
- каждой строке/столбцу нужно дать заголовок;
- иногда полезно объединять заголовки под одним общим;
- полезно указать источник данных для таблицы;
- не забывайте указывать единицы измерения.

Статистические расчеты всегда были очень трудоемким делом. Менеджеры – занятые люди, их время, потраченное работу с данными, должно стоить меньше, чем выгода от более качественного управленческого решения.

Существует множество программ для обработки данных. Очень распространены электронные таблицы EXCEL, эта программа есть на каждом компьютере, однако ее возможности довольно скромны по сравнению со специальными программами, например, STATISTICA или SPSS.

Определение наибольшего и наименьшего значения в диапазоне данных
Для этого раздела можно использовать

Наибольшее =МАКС(данные) Наименьшее =МИН(данные)

Сводные таблицы

ДАННЫЕ – СВОДНАЯ ТАБЛИЦА (из меню)

Получение частоты значения переменной или ее попадания в интервал
=ЧАСТОТА(массив данных, массив интервалов)

2. Графическое представление данных

При использовании любой формы графического представления данных нужно не забывать о названии, маркировке и размерности осей и разумном масштабе, также будет полезна ссылка на источник информации. Это гарантирует, что график будет понятен тем, кто слушает Вашу презентацию.

2.1 Представление категориальных данных

Имеются два основных способа для представления этого типа данных:

1. *Столбиковая диаграмма* - наиболее часто используемый тип диаграмм, он применяется, чтобы показать соотношение частот для разных категорий.

Каждое значение категориальной переменной представлено столбиком, частота – высотой столбика.



Более сложный вариант столбиковой диаграммы – многокомпонентная столбиковая диаграмма. Она включает два или более набора данных. Например, может показать распределение типа жилищных условий для мужчин и женщин.

Обратите внимание, в этой диаграмме частота относительная, а не абсолютная, т.к. категории расслоения «мужчина» и «женщина» в общем случае могут иметь разный объем.




Еще один тип столбиковой диаграммы – составная столбиковая диаграмма. Эта диаграмма дает возможность представить структуру категории.



2. Секторная диаграмма

Полный набор данных представлен кругом, и каждая категория представлена частью этого круга, то есть сектором. Частота категории – угол сектора. Используется, чтобы показать, какую часть от целого составляет категория. Диаграмма полезна, если число категорий невелико, и каждая – существенная часть полных данных.



2.2. Представление количественных данных

Имеются три основных способа для представления этого типа данных:

1. Гистограмма

Гистограмма является самым лучшим средством представления данных таблиц частот (в предыдущем разделе таблицами частот были 1б, 1г и 1д).

Хотя на первый взгляд гистограмма, очень похожа на столбиковую диаграмму, но ее горизонтальная ось имеет количественную, а не категориальную шкалу, а столбики (отличительная особенность) соединены вместе. Гистограмма представляет собой частотное распределение количественной переменной.


Примечание. Если не указано иное, то обычно правая граница интервала включается, а левая нет, когда интервалы (первый столбик) записаны таким образом:

Таблица 2а

Ежемесячные расходы на жилье

Ежемесячные расходы на жилье, \$	Средняя точка интервала, \$	Частота	Относительная частота, %
90 - 100	95	1	3
100 - 110	105	2	6
110 - 120	115	3	8
120 - 130	125	8	22
130 - 140	135	13	36
140 - 150	145	5	14
150 - 160	155	3	8
160 - 170	165	1	3
Всего	—	36	100


Гистограмма расходов на жилье




2. Частотный график

Частотный график по процедуре построения аналогичен гистограмме. Его применяют, когда распределения двух или больше количественных переменных должны быть представлены на одном и том же рисунке.

Гистограмма расходов на жилье "студентов-женщин"




Гистограмма расходов на жилье "студентов-мужчин"



Если нужно совместить эти две гистограммы, то их представляют одним частотным графиком. Иногда в статистических программах его называют POLYGON

Частотный график расходов на жилье "студентов-мужчин" и "студентов-женщин"



Кумулятивный частотный график


Этот график представляет данные, используя кумулятивную (накопленную) частоту. Это полезно для вычисления персентилей и некоторых статистических величин.

Таблица 26

Ежемесячные расходы на жилье

Ежемесячные расходы на жилье, \$	Правая точка интервала, \$	Частота	Относительная частота, %	Кумулятивная частота, %
90 - 100	100	1	3	3
100 - 110	90	2	6	9
110 - 120	100	3	8	17
120 - 130	110	8	22	39
130 - 140	120	13	36	75
140 - 150	130	5	14	89
150 - 160	140	3	8	97
160 - 170	150	1	3	100
Всего	—	36	100	—

Кумулятивный частотный график расходов на жилье



Такой график может использоваться для различных оценок. Например, какая доля студентов платит меньше, чем \$135?

3. Простой график

Этот график используется для того, чтобы показать связь между переменными, наиболее часто для отображения данных за определенный пе-

риод времени. Ось x – время, ось y – переменная (продажи, прибыль, издержки производства и т.д.) Нанесенные точки обычно соединяются линией.



Разновидность этого типа графика – диаграмма рассеяния.

Используется для визуального определения наличия и силы связи между переменными. Например, существует ли связь между возрастом студента и тем, сколько он расходует на жилье?



В данных материалах представлены только основные типы диаграмм/графиков. Просмотрев газету, журнал, рекламный проспект, можно найти огромное разнообразие их видов и комбинаций, но в основе всех лежат типы, перечисленные выше.

Все представленные графики можно построить при помощи команды Вставка-Диаграмма. Трудности возникают только при построении гистограмм. Среди многочисленных типов диаграмм самой первой EXCEL предлагает гистограмму, но здесь имеет место неточность перевода, на самом деле это – столбиковая диаграмма. Еще одна возможность построить гистограмму предлагается в меню Сервис-Анализ данных, но и эта гистограмма строится не совсем корректно.

Рекомендуется сделать заготовку таблицы, пользуясь функцией ЧАСТОТА, добавить столбик средних точек интервалов и построить по этим данным гистограмму как простую столбиковую диаграмму.

3. Сбор данных

Методы сбора данных экономического и технического характера (объем производства, расходы, уровень брака, количество нарушений и т.п.), как правило, известны менеджерам и широко применяются.

Трудности чаще возникают при определении критериев в области улучшения деятельности персонала. Успешность проведенных мероприятий во многих случаях крайне уязвима для критики с точки зрения методов сбора данных.

Изучение, измерение, мониторинг состояния социальной системы предприятия, цеха, участка – необходимый элемент современного менеджмента.

3.1 Методы сбора первичных данных

- анкетные опросы

Дешевый и быстрый метод. Требует тщательной разработки вопросов и качественного оформления анкеты. Может быть неэффективным, если не обеспечивается возврат анкет. При анонимном анкетировании необходимо быть уверенным в искренности респондентов и их желании сотрудничать.

- личные интервью

Эта процедура обычно дорога и требует участия опытных специалистов в качестве интервьюеров. Используется, когда нужно выяснить мнение людей по «трудным» вопросам (отношение работников к изменениям условий труда, оплаты, сокращениям, реструктуризации и т.п.) Любая противоречивая или шокирующая информация обычно считается неприемлемой при проведении анкетирования, и тогда применяют личные интервью.

- наблюдения

Этот метод используется, когда интересуется не мнение людей, а изучение некоторых событий. Например, при исследовании методов труда, возможно, лучше провести наблюдения, чем опросы. Точность метода зависит от навыков наблюдателя. Метод может требовать много времени, если придется наблюдать нерегулярные события.

3.2 Составление вопросов

Изучать мнение людей, не задавая им вопросы, довольно сложно. Вопросы нужны как в анкетах, так и в интервью. Хорошо построенные вопросы – критический фактор успеха таких исследований.

Имеются три основных типа вопросов, используемые в анкетах.

- вопросы с выбором из двух вариантов

В них имеются два возможных ответа. Например, «Да» или «Нет»; «Мужчина» или «Женщина»; «Истина» или «Ложь»; «Любите» или «Не любите».

1.	Вы живете в общежитии?	☐	да	☐	нет
2.	Ваш преподаватель	☐	мужчина	или	☐ женщина?
3.	$7*3=20$	☐	истина	или	☐ ложь?
4.	Вы	☐	любите	или	☐ не любите математику?

Удостоверьтесь, что вопросы этого типа не используются там, где возможно некоторое среднее мнение или полное отсутствие мнения, как в вопросе №4.

- многовариантные вопросы

Здесь респонденты могут выбирать из нескольких обозначенных возможностей. В эту категорию включены и те вопросы, в которых респондента могут просить ранжировать варианты ответов.

Важно удостовериться, что перечисленные варианты охватывают все возможные ответы и являются взаимоисключающими, то есть каждый респондент может выбрать только один из вариантов.

Где Вы живете?			
Общежитие	☐	Арендуете комнату	☐
Собственная комната	☐	Арендуете квартиру	☐
Собственная квартира	☐		
Другое (пожалуйста, укажите) _____			

Категория «Другое» предназначена для ответов, которые были пропущены в основном списке.

Удостоверьтесь также, что она не станет наиболее популярным выбором у респондентов.

Когда задаете вопросы, определяющие отношение, обеспечьте равное количество ответов «за» и «против».

Вы думаете, что обслуживание в столовой ...?							
↑	отличное	↑	хорошее	↑	удовлетворительное	↑	плохое

Здесь имеются 3 выбора со знаком «+» и только 1 со знаком «-»

Всякий раз, когда необходимо, не забудьте оставить выбор «не знаю», «не имею», «не использую».

- открытые вопросы

Респонденты могут отвечать на такие вопросы, что пожелают. Главное преимущество этого типа вопросов состоит в том, что они учитывают бесконечное количество разнообразных ответов. Как ни странно, это – неудобство, поскольку ответы на такие вопросы – самые трудные для обработки и анализа. Таким образом, не стоит использовать их слишком много в одной анкете.

Можно сказать, что открытые вопросы полезны в трех областях:

1 В пилотных исследованиях они могут использоваться, чтобы определить

все возможные варианты ответа на вопрос. Тогда в широкомасштабном исследовании этот вопрос станет хорошо разработанным многовариантным вопросом.

Что можно предпринять для решения проблемы Z?

2. Как дополнительный вопрос в зависимости от выбора, сделанного в предыдущем вопросе.

Улучшило ли мероприятие N распределение работ в отделе?

☐ Да ☐ Нет, если выбрано Нет, пожалуйста, кратко объясните почему

3. Расположенный в конце анкеты открытый вопрос предоставляет респонденту шанс добавить что-нибудь, что он считает важным, но что не охвачено предыдущими вопросами.

При составлении вопросов для анкеты необходимо помнить:

- Анкеты должны быть короткими, насколько это возможно.

- Сами вопросы должны

- не содержать сложных незнакомых слов и фраз;
- быть однозначно понимаемыми;
- не требовать слишком много вычислений и не напрягать память;
- не быть слишком личными или вызывающими.

- Вопросы должны быть выстроены в логическом порядке.

- Анкеты должны быть привлекательно оформлены.

Как ответы будут анализироваться, следует продумать на стадии проектирования анкеты.

3.3 Выборочные исследования

Исследование может быть полным или выборочным. При полном исследовании собираются сведения о всей совокупности объектов. Выборочное предполагает сбор данных по выборке из генеральной совокупности и распространение всех выводов, сделанных в исследовании на всю совокупность.

Выборочные исследования используются по двум причинам:

- желание уменьшить расходы при приемлемой точности результатов, (частичная перепись населения, выборочный контроль качества);
- недоступность всей генеральной совокупности (опрос покупателей в магазине, контроль качества с разрушением образцов).

Определение размера выборки

Не существует твердого правила для определения оптимального

размера выборки для любого случая. Однако есть два момента, которые следует учитывать:

Чем больше размер выборки, тем более точной будет информация о совокупности.

Начиная с некоторого размера выборки, дополнительная информация, которая может быть получена о совокупности, не стоит потраченных усилий, времени и денег.

Если заранее заданная точность не является обязательным требованием к вашему исследованию, то элементарного здравого смысла в сочетании с некоторой известной информацией будет достаточно, чтобы определиться с размером выборки. Следующие примеры иллюстрируют этот подход.

Пример 1

IT-менеджер компании желает изучить мнение пользователей о работе сети.

В этом случае никакая специальная информация не требуется. Результаты не будут иметь никакого прямого воздействия на самих опрашиваемых. Компьютерами регулярно пользуются все сотрудники компании. Размер выборки 50–100 человек был бы достаточен.

Пример 2

Директор бизнес-школы хотел бы удлинить учебную неделю и включить в нее субботнее утро. Он желает знать, как к этому отнесутся студенты и персонал.

В этом случае, результат исследования может вызвать крупное изменение в жизни бизнес-школы. Было бы желательно сначала установить размер всей совокупности (штат и студенты) и затем сделать выборку от 20 % до 30 %.

Пример 3

Библиотека рассматривает возможность выписать журналы по определенному узкому направлению. Библиотека должна оценить ее потенциальное использование сотрудниками.

В этой ситуации, кто-то может иметь слабый интерес, а кто-то будет очень заинтересован. Справедливо предположить, что заинтересованные составляют малую часть. Чтобы гарантировать, что, они попадут в выборку, ее размер должен быть больше, чем в других случаях.

Обеспечение репрезентативной выборки

Также как и в определении размера выборки, здравый смысл – главный помощник в обеспечении репрезентативной выборки.

Пример 1

Вас попросили выяснить среднюю цену трехкомнатной квартиры в центре города.

В этом случае Вы бы не могли просто пойти в ближайшее агентство недвижимости, просмотреть цены на 20 (или даже 120) квартир и ожидать, что получили репрезентативную выборку. (Почему?)

Пример 2

Руководство объединения столовых желает знать мнение посетителей о работе столовой №1.

В этом случае разумно предположить, что выяснение мнения 50 - 100 человек на выходе из здания столовой даст репрезентативную выборку

3. Методы выборки

Доступно множество методов, чтобы получить репрезентативную выборку:

- простая случайная выборка

Каждый участник совокупности должен иметь равный шанс быть включенным в выборку. Для маленьких совокупностей это может быть метод «вытаскивания бумажек из шляпы». Для больших совокупностей каждому участнику совокупности дают индивидуальный номер и делают выборку методом генерации случайных чисел при помощи компьютера, таблицы случайных чисел. С помощью этого типа выборки производится большинство телефонных опросов и опросов по каким-либо спискам. Для построения случайной выборки необходим список всех элементов генеральной совокупности.

Преимущества	Предубежденность отсутствует.
Недостатки	Просто случайно может получиться нетипичная выборка. Сбор удаленных (в пространстве) данных может оказаться трудным.

- стратифицированная (расслоенная) случайная выборка

Чтобы избежать опасности получить нетипичную выборку, ее можно стратифицировать. Например, если в компания работают 800 мужчин и 200 женщин, то выборка должна отразить отношение 4 мужчины и 1 женщина. Для каждой страты, участники отбираются беспорядочно.

Преимущества	Предубежденность отсутствует или незначительная. Размер относительно маленький.
Недостатки	Необходимо заранее иметь информацию о совокупности. Дополнительные затраты на стратификацию.

- систематическая выборка

Метод похож на простую случайную выборку за исключением того, что вместо использования генератора случайных чисел, данные располагаются в случайном порядке, и каждый n-ый член отбирается.

$$n = (\text{размер совокупности}) / (\text{желаемый размер выборки})$$

По этому принципу могут отбираться образцы продукции, сходящие с конвейера для контроля качества (например, первые два образца, сошедшие с конвейера с начала часа).

Преимущества	Легче использовать, чем просто случайную выборку.
---------------------	---

Недостатки Может происходить искажение, если в порядке данных имеется закономерность, которая совпадет со значением n .

- кластерная выборка

Этот метод часто используется, когда совокупность недоступна, а данные, как полагают, являются гомогенными (равномерно распределенными по совокупности). Для удобства берется сконцентрированная группа данных (например, в пространстве или за короткий промежуток времени).

Преимущества Довольно дешевый способ, когда имеют дело с большой компанией. Является хорошим методом, когда Вы не совсем уверены, какая именно совокупность Вас интересует.

Недостатки Подвержен искажениям, поскольку это «неслучайная» техника.

- квотированная выборка

Фактически, это усложненный вариант стратифицированной выборки. Часто используется для интервьюирования. Интервьюеру дают «структурированный» профиль выборки. Интервьюер случайным образом выбирает людей из совокупности, пока все квоты не будут заполнены.

Например, на основе таблицы ниже интервьюеру нужно всего в 40 человек, двое из них будут женщины – менеджеры в возрасте от 45 до 60, и т.д.

Социальный класс	Менеджеры		Специалисты		Рабочие	
Возраст / пол	М.	Ж	М.	Ж	М.	Ж
18-29	1	0	3	1	2	2
30-44	1	1	3	2	4	3
45-60	2	2	3	1	2	2
60 или более	1	0	2	1	1	0

Преимущества Полное совпадение долей в выборке и совокупности. Сравнительно низкие затраты.

Недостатки Очень зависит от навыков интервьюера, «неслучайная» техника.

Источники ошибок

Никакое исследование не может быть точным на 100%.

Ошибка может быть систематической – тогда, когда она заложена в саму процедуру отбора, т.е. выборка получилась нерепрезентативной. Ошибок, возникающих из-за нерепрезентативности выборок, можно избежать, тщательно продумывая, какой метод выборки использовать.

Случайная ошибка возникает в силу того обстоятельства, что опрошена

не вся генеральная совокупность. В этом случае точность результатов можно оценить.

Ошибки, возникающие по другим причинам:

- **Неправильная запись данных в компьютер для обработки.**
- **Отказ от сотрудничества со стороны участников выборки.**
- **Плохо разработанные вопросы.**

4. Меры среднего

Графическое представление данных само по себе очень информативно. Но этого не достаточно, чтобы сделать выводы о том, как часто встречается то или иное значение переменной, как оно может меняться, от каких факторов зависеть, каким закономерностям подчиняется и о многом другом. Чтобы получить такую информацию, в статистическом анализе используются различные формальные характеристики.

Анализ, как правило, начинают с вычисления *среднего значения*.

Существуют три наиболее распространенные величины среднего:

- среднее арифметическое

Это – то самое среднее значение, которое используется в каждодневных ситуациях. Для несгруппированных данных его находят, складывая все числа и деля сумму на их количество.

Преимущества Обычно считается «стандартным» средним числом
При его вычислении учитывается величина ВСЕХ значений

Недостатки С точки зрения математики, с ним легко работать
Тяжелее находить, чем моду и медиану
Чувствительно к экстремальным значениям.

Примеры

Исходные данные – отдельные значения

Арифметическое среднее из набора n чисел $x_1, x_2, \dots, x_n$ обозначается $\bar{x}$ и вычисляется как

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} \quad \text{или} \quad \bar{x} = \frac{\sum x}{n}$$

Например.

63	68	63	72	73	65
x_1	x_2	x_3	x_4	x_5	x_6

$$\bar{x} = \frac{63 + 68 + 63 + 72 + 73 + 65}{6} = 67.3$$

Исходные данные – частотное распределение для отдельных значений

Арифметическое среднее из набора чисел $x_1, x_2, \dots, x_n$ встречающихся с частотой $f_1, f_2, \dots, f_n$ вычисляется как

$$\bar{x} = \frac{f_1 x_1 + f_2 x_2 + \dots + f_n x_n}{f_1 + f_2 + f_3 + \dots + f_n} \quad \text{или} = \frac{\sum f_i x_i}{\sum f_i} \quad \text{или} = \frac{\sum f x}{\sum f}$$

Например.

x	f	f · x
1	8	1 · 8 = 8
2	10	2 · 10 = 20
3	9	3 · 9 = 27
4	7	4 · 7 = 28
5	11	5 · 11 = 55
6	15	6 · 15 = 90
Сумма	60	228

$$\bar{x} = \frac{\sum f x}{\sum f} = \frac{228}{60} = 3.8$$

Исходные данные – частотное распределение для сгруппированных значений

Определяется, как и в предыдущем случае. За x принимается средняя точка каждого интервала.

Продажи, £	Средняя точка интервала x, £	f	f · x
20 - 30	25	4	100
30 - 40	35	14	490
40 - 50	45	17	765
50 - 60	55	25	1375
60 - 70	65	20	1300
70 - 80	75	14	1050
80 - 90	85	6	510
Сумма	–	100	5590

$$\sum f x = 5590 \quad \sum f = 100$$

$$\bar{x} = \frac{\sum f x}{\sum f} = \frac{5590}{100} = 55.9$$

- мода

Мода – значение переменной, которое встречается наиболее часто.

Применяется как к количественным, так и к категориальным переменным.

Преимущества Легко находить

Легко понимать

Не зависит от экстремальных значений переменной

Недостатки

Может не существовать

Может быть не единственной

Нельзя определить ее точно, когда данные сгруппированы

Не очень полезна в арифметических вычислениях

Примеры

Исходные данные – отдельные значения

1) 2 5 7 9 9 9 10 10 11 12

Мо = 9 (так как 9 встречается 3 раза)

2) 2 5 7 7 7 9 9 9 10 10 11 12

Мо = 7 или 9 (то и другое встречается 3 раза) – не единственная.

3) 3 5 7 8 10 12 15 16

Моды нет

4) 2 5 7 9 9 9 10 11 1024

Мо = 9 – очень большое по сравнению с остальными значение 1024 не оказывает никакого влияния.

Исходные данные – частотное распределение для отдельных значений

Мода - значение переменной с самой большой частотой

x	f
1	3
2	9
3	12
4	11
5	6

←Самая большая частота
Мо = 3

Исходные данные – частотное распределение для сгруппированных значений с равными интервалами

Для сгруппированных данных мы можем идентифицировать только *модальный класс*.

Интервал (класс)	Частота
0-10	11
10-20	26
20-30	32
30-40	18
40-50	4

←Самая большая частота
модальный класс - 20-30

- медиана

Медиана – значение переменной, которая делит упорядоченные данные на две равные половины. Можно применять к количественным данным и к категориальным, если их можно упорядочить.

Преимущества Легко находить

Легко понимать

Не зависит от экстремальных значений переменной

Недостатки

Не очень полезна в арифметических вычислениях

Примеры

Исходные данные – отдельные значения

1) 4 5 3 8 10 8 8 6 4 – нечетное число

Сначала выстраивают данные в порядке возрастания

То есть 3 4 4 5 **6** 8 8 8 10

Центральное 5-ое значение равно 6. Таким образом, Ме= 6

2) 7 18 15 5 9 12 5 11 - четное число

Выстраивают данные в порядке возрастания

То есть 5 5 7 **9 11** 12 15 18

Центрального значения нет, поэтому берем среднее двух центральных значений

$$Me = (9+11)/2 = 10$$

Исходные данные – частотное распределение для отдельных значений

x	f	кумулятивная f
1	3	3
2	8	11
3	12	23
4	7	30
Сумма	30	

← значение $(n + 1)/2 = 15.5$

Если бы мы упорядочили эти данные, то имели бы

1 1 1 2 2 2 2 2 2 2 3 3 3 **3 3 3 3 3 3 3 3 3** 4 4 4 4 4 4 4

Медиана - среднее двух центральных значений 15-ого и 16-ого, $Me = (3+3)/2 = 3$

Очевидно, что этот путь тяжел. Более легкий путь состоит в том, чтобы ввести колонку кумулятивной частоты и найти, где находится значение $(n + 1)/2$

В нашем примере, $(n+1)/2 = (30+1)/2 = 15.5$.

В колонке кумулятивной частоты ищем ближайшие нижнее и верхнее значение, это 11 и 23.

Медиана попадает на значение x равное 3, т.е. $Me=3$

Исходные данные – частотное распределение для сгруппированных значений

Имеются два способа определения медианы для этого случая. Один использует алгебраический метод; другой – графический метод. Здесь представлен второй.

1. Нарисовать кумулятивный график относительной частоты.
2. От значения 50% провести горизонтальную линию до пересечения с графиком.
3. Из точки пересечения опустить перпендикуляр.
4. Пересечение перпендикуляра с горизонтальной осью даст медиану.

Интервал, число заказов в день	Правая граница	Частота	Относительная частота	Кумулятивная частота
0-10	10	11	12	12
10-20	20	26	29	41
20-30	30	32	35	76
30-40	40	18	20	96
40-50	50	4	4	100
Сумма	—	91	100	—

Например, для сгруппированных данных, представленных в таблице, получим графически, что медиана приблизительно равна 22,5. Таким образом, можно полагать, что в половине случаев число заказов в день было не более 22.




- симметричные и несимметричные распределения


Построения гистограммы обычно достаточно, чтобы определить на глаз, является набор данных симметричным или нет.

Симметричные распределения часто получаются при измерении физических величин, когда шкала может рассматриваться как неограниченная с обеих сторон. Например, вес стандартной упаковки, диаметр однотипной детали, расход топлива машин одной модели.


Для идеально симметричного распределения мода, медиана и среднее арифметическое совпадают. Чем несимметричнее распределение, тем больше эти величины отличаются.



Как правило, несимметричное распределение имеет короткий хвост с одной стороны моды и длинный – с другой. В этом случае среднее арифметическое сильно зависит от крайних значений, поэтому медиана или мода больше подходят на роль «среднего значения». В общем случае, медиана обычно более уместна, чем мода, если данные не очень сильно искажены.



Положительно скошенное распределение: мода < медиана < среднее арифметическое



Отрицательно скошенное распределение: среднее арифметическое < медиана < мода

Несимметричные распределения встречаются довольно часто, например, заработная плата, количество нарушений за период, задержка выполнения заказов, отклонения от бюджета. Несимметричные распределения также характерны для случаев, когда есть ограничитель шкалы, например, % брака стремится к нулю, а % выполнения заказов к 100%.

Иметь дело с несимметричными распределениями тяжелее с точки зрения обработки данных и интерпретации результатов. Поэтому, по возможности, делают предположения об их симметричности. В этом курсе предлагается использовать формальный критерий – функцию СКОС в Excel (формулу вы найдете в справке, если потребуется). Если значение этой функции для набора данных оказывается по модулю меньше единицы, то распределение считается симметричным, и для его описания используются характеристики *нормального* распределения.

Однако никакой формальный критерий не может заменить визуальную проверку исходных данных с помощью обычной гистограммы.

Если исходные данные представляют собой отдельные значения, можно использовать функции:

Среднее арифметическое: =СРЗНАЧ (данные)

Мода: =МОДА (данные)

Медиана: =МЕДИАНА (данные)

Асимметрия = СКОС (данные)

Кроме того, можно воспользоваться встроенным пакетом анализа:

Сервис – Анализ Данных – Описательная статистика

5. Меры вариации

Меры среднего являются важной характеристикой данных, однако, во многих случаях они недостаточны. Показатели среднего не в состоянии указать, насколько данные разбросаны. Ниже рассмотрены величины, по которым можно определить вариацию внутри набора данных

5.1 Размах

Это самая простая мера вариации данных – разница между самым большим и самым маленьким значением в наборе данных. Часто используется для сильно несимметричных распределений.

Например	1) 6 0 1 0 0 5	Размах = $6 - 0 = 6$
	2) 1 2 2 2 3 2	Размах = $3 - 1 = 2$
	3) 0 35 42 43 45 46 47 52 100	Размах = $100 - 0 = 100$
	4) 0 7 21 32 45 52 58 82 100	Размах = $100 - 0 = 100$


Сравнение 3) и 4) показывает, что оба имеют размах 100, хотя в пределах этого размаха данные весьма различны. Это иллюстрирует, что размах зависит от двух крайних значений и полностью игнорирует то, что происходит между ними.

5.2 Межквартильный размах

Размах может быть легко искажен отдельными экстремальными значениями. Для сравнения наборов данных более приемлемой величиной считается значение межквартильного размаха. Незаменимая характеристика для несимметричных распределений.

Межквартильный размах – это размах для центральных 50% данных.

На рисунке представлено частотное распределение набора данных. Если мы исключим 25% наименьших значений и 25% наибольших значений, то получим размах, включающий центральные 50% значений, т.е. межквартильный размах.



Два крайних значения из центральных 50% называются квартилями.

Межквартильный размах – расстояние между нижним квартилем Q_1 и верхним квартилем Q_3 .

Квартили можно получить аналогично тому, как мы определяли медиану ранее. Нижний квартиль находится на расстоянии $\frac{1}{4}$ от начала распределения, а верхний квартиль – на расстоянии $\frac{3}{4}$.

Нижний (первый) квартиль $Q_1 \rightarrow \frac{1}{4}(n+1)$ -е порядковое значение

Верхний (третий) квартиль $Q_3 \rightarrow \frac{3}{4}(n+1)$ -е порядковое значение

Медиана (второй квартиль) – это середина распределения, и она является $Q_2 \rightarrow \frac{1}{2}(n+1)$ -м порядковым значением.

Обратите внимание, медиана – это второй квартиль Q_2 . Но совершенно необязательно, чтобы медиана являлась средним арифметическим величин Q_1 и Q_3 .

Когда необходимо отсечь не 25% наименьших значений, а некое произвольное количество процентов, то пользуются понятием *персентиль*.

Примеры

Исходные данные – отдельные значения

Найдите межквартильный размах двух наборов чисел

а) 8 9 7 10 5 4 6 и б) 12 12 3 8 9 9 5 6 3 4 5 11

Решение

а) Имеется 7 чисел. Выстраиваем их в порядке возрастания

4	5	6	7	8	9	10	n=7
	↑		↑		↑		
	Q_1		Q_2		Q_3		

медиана

Нижний (первый) квартиль $Q_1 \rightarrow \frac{1}{4}(n+1)$ -е порядковое значение, т.е. $\frac{1}{4}(7+1)=2$ -е

Верхний (третий) квартиль $Q_3 \rightarrow \frac{3}{4}(n+1)$ -е порядковое значение, т.е. $\frac{3}{4}(7+1)=6$ -е

Медиана (второй квартиль) $Q_2 \rightarrow \frac{1}{2}(n+1)$ -е порядковое значение, т.е. $\frac{1}{2}(7+1)=4$ -е

Таким образом, межквартильный размах $Q_3 - Q_1 = 9 - 5 = 4$

б) Имеется 12 чисел. Выстраиваем их в порядке возрастания

3	3	4	5	5	6	8	9	9	11	12	12	n=12
		↑			↑			↑				

$$Q_1 = (4+5)/2$$

$$Q_2 = (6+8)/2$$

$$Q_3 = (9+11)/2$$

Нижний (первый) квартиль $Q_1 \rightarrow \frac{1}{4}(n+1)$ -е порядковое значение, т.е. $\frac{1}{4}(12+1)=3.25$ -е

Верхний (третий) квартиль $Q_3 \rightarrow \frac{3}{4}(n+1)$ -е порядковое значение, т.е. $\frac{3}{4}(12+1)=9.75$ -е

Медиана (второй квартиль) $Q_2 \rightarrow \frac{1}{2}(n+1)$ -е порядковое значение, т.е. $\frac{1}{2}(12+1)=6.5$ -е

Таким образом, $Q_1 = 4,5$ $Q_2 = 7$ $Q_3 = 10$

и $Q_3 - Q_1 = 10 - 4,5 = 5,5$

Обратите внимание, $Q_2 \neq \frac{1}{2}(Q_1 + Q_3)$

Исходные данные – частотное распределение для отдельных значений

Процедура вычисления квартилей аналогична процедуре вычисления медианы.

$\frac{1}{4}(n+1)$ -е порядковое значение соответствует нижнему квартилю Q_1

$\frac{3}{4}(n+1)$ -е порядковое значение соответствует верхнему квартилю Q_3

Необходимо построить колонку кумулятивной частоты и определить, чему равны $\frac{1}{4}(n+1)$ -е и $\frac{3}{4}(n+1)$ -е порядковые значения.

Исходные данные – частотное распределение для сгруппированных значений

Можно воспользоваться графиком кумулятивной частоты. Алгоритм тот же, что и при нахождении медианы.

Значения 25% и 75% нужно найти на вертикальной оси, а соответствующие им значения на горизонтальной оси будут значениями квартилей.

5.3. Стандартное отклонение и дисперсия

Типичные характеристики нормального распределения, используются для описания симметричных наборов данных, где $|\text{СКОС}| < 1$

Если в вашем распоряжении находятся данные выборочного исследования, которые представлены как **отдельные значения**, то

стандартное отклонение по выборке рассчитывается как
$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

Если результаты выборочного исследования представлены как **частотное распределение**, то

стандартное отклонение по выборке рассчитывается как
$$s = \sqrt{\frac{\sum f(x - \bar{x})^2}{\sum f - 1}}$$

дисперсия = (стандартное отклонение) 2 = s^2

Примеры

Исходные данные – отдельные значения

Найдите среднее арифметическое, стандартное отклонение и дисперсию набора выборочных данных 2, 3 и 7.

ответ

$$\bar{x} = 4 \quad s = 2.65 \quad s^2 = 7.00 \quad \left(\sum (x - \bar{x})^2 = 14 \right)$$

Исходные данные – частотное распределение для отдельных значений

Найдите среднее, стандартное отклонение и дисперсию для частотного распределения выборочных данных,

x	f
1	8
2	10
3	12
4	14
5	6
6	10

ответ

$$\bar{x} = 3.5, \quad s = 1.62 \quad s^2 = 2.63 \quad \left(\sum fx = 210, \sum f = 60, \sum f(x - \bar{x})^2 = 155 \right)$$

Исходные данные – частотное распределение для сгруппированных значений

Процедура вычисления – точно такая же, как выше, только за значения x берутся средние точки интервалов. Например,

Стоимость (\$)	Средняя точка	f
20 - 29	24.5	4
30 - 39	34.5	14
40 - 49	44.5	17
50 - 59	54.5	25
60 - 69	64.5	20
70 - 79	74.5	14
80 - 89	84.5	6

ответ

$$\bar{x} = 55.4, s = 15.51 \text{ и } s^2 = 240.60 \quad (\sum fX = 5540, \sum f = 100, \sum f(x - \bar{x})^2 = 23819)$$

Приведенные выше формулы применяются к выборкам, а полученные значения $\bar{x}$ и s – это точечные оценки параметров генеральной совокупности.

Если вы измерили генеральную совокупность полностью, т.е. ваше исследование не выборочное, а полное, то вы можете рассчитать истинные параметры генеральной совокупности.

Среднее арифметическое генеральной совокупности рассчитывается точно так же, как и для выборки, но обозначается символом μ (мю), а не $\bar{x}$.

Для отдельных значений $\mu = \frac{\sum x}{N}$, для частотных распределений $\mu = \frac{\sum f x}{\sum f}$

Стандартное отклонение генеральной совокупности обозначается символом σ (сигма), а дисперсия – σ^2 (сигма квадрат)

$$\text{Для отдельных значений } \sigma = \sqrt{\frac{\sum (x - \bar{x})^2}{N}}, \quad \text{для частотных распределений } \sigma = \sqrt{\frac{\sum f(x - \bar{x})^2}{\sum f}}$$

В EXCEL имеются встроенные функции и их комбинации:

Размах = МАКС(Данные) - МИН(Данные)

Нижний квартиль = КВАРТИЛЬ (Данные, 1)

Верхний квартиль = КВАРТИЛЬ (Данные, 3)

Межквартильный размах = КВАРТИЛЬ (Данные, 3) - КВАРТИЛЬ (Данные, 1)

Персентиль = Персентиль (Данные, доля)

Стандартное отклонение (по выборке) = СТАНДОТКЛОН(Данные)

Стандартное отклонение (по генеральной совокупности) = СТАНДОТКЛОНП(Данные)

6. Введение в статистический вывод

Ранее уже обсуждались понятия *выборка* и *генеральная совокупность*. Рассмотрим их еще раз подробнее. Термин *генеральная совокупность* (далее *совокупность*) обозначает группу людей, предметов или явлений, с которыми связано статистическое исследование. Чтобы судить о свойствах совокупности, лучше всего было бы рассмотреть и измерить все ее элементы,

но из-за ограничений времени и стоимости это часто неосуществимо. Поэтому исследуют только некоторую часть совокупности – *выборку*, которая должна представлять всю совокупность.

Использование данных, полученных по выборкам, неизбежно приводит нас в область статистического вывода.

Статистический вывод – процесс, в котором данные выборки/выборок из одной или более генеральных совокупностей анализируются, а затем делаются утверждения (выводы) о свойствах тех совокупностей, из которых эти выборки были взяты.

Целью статистического вывода может быть:

- измерение параметра совокупности (например, уровень ошибок, допускаемых оператором, доля рабочих, поддерживающих новые методы работы)

- проверка доверия к утверждениям (предположениям) относительно совокупности (например, изменение режима работы операторов привело к уменьшению ошибок, отношение рабочих к новым методам улучшилось)

Будем использовать термин *параметр* для характеристики совокупности и термин *статистика* для соответствующей характеристики выборки. Различия в обозначениях приведены в таблице.

	Параметры совокупности	Статистики выборки
Среднее арифметическое	μ	$\bar{x}$
Стандартное отклонение	σ	s
Доля	p	$\hat{p}$
Размер	N	n

Чем больше размер выборки, тем точнее будет оценка параметров генеральной совокупности.

6.1. Доверительный интервал для среднего

Пример

Менеджер печатного центра бизнес-школы желает оценить средний размер студенческих работ, чтобы впоследствии оценить потребность в ресурсах. Он взял случайную выборку из 50 заказов и вычислил ее следующие статистики:

Среднее $\bar{X}_1$ страниц Стандартное отклонение s_1 страниц

Это среднее $\bar{X}_1$ менеджер может использовать как точечную оценку среднего совокупности

$$\mu = \bar{X}_1$$

Однако менеджер может взять и другую выборку из 50 заказов и вычислить ее статистики:

Среднее $\bar{X}_2$ страниц Стандартное отклонение s_2 страниц

Второй набор статистик, вероятно, будет отличаться от первого. И каждая следующая выборка вполне даст новые значения.

Менеджер теперь может вычислить диапазон, внутрь которого с заданной вероятностью попадает параметр генеральной совокупности, – так называемый *доверительный интервал*.

$$\mu = \bar{X} \pm t_{\alpha/2 (n-1)} \frac{s}{\sqrt{n}}$$

Доверительный интервал для параметра не значит, что параметр совокупности может принимать любые значения внутри этого интервала, но можно утверждать, что этот интервал «накрывает» точное значение параметра с заранее известной вероятностью.

Эту вероятность нужно задать, исходя из того, насколько надежным должно быть решение по результатам обработанных данных. Чем выше требования к надежности, тем шире получается интервал. Известно, что чем «шире» прогноз погоды, тем чаще он сбывается.

Обычно в коммерческих решениях используется вероятность 95%. Это значит, что вы будете ошибаться в определении доверительного интервала примерно 5 раз из 100. Или другими словами, если бы вы брали выборки из одной и той же совокупности бесконечное число раз, то примерно 5 выборок из 100 оказывались бы «неудачными», и рассчитанный по ним доверительный интервал был бы неправильным.

Увеличивая размер выборки можно сузить интервал. Если ширина интервала задана, можно примерно рассчитать необходимый размер выборки.

Пример (продолжение)

Менеджер печатного центра желает оценить средний размер работ, получаемых его отделом. Выборка из 50 заказов была отобрана случайным образом, было найдено среднее – 70 страниц и стандартное отклонение – 25 страниц. Менеджер хочет вычислить 95% доверительный интервал для среднего размера всех работ, то есть среднее совокупности μ .


Статистики выборки:

$$\bar{X} = 70, \quad s = 25, \quad n = 50$$

Для того, чтобы воспользоваться формулой $\mu = \bar{X} \pm t_{\alpha/2 (n-1)} \frac{s}{\sqrt{n}}$, нужно выбрать в таблице распределения

Стьюдента коэффициент $t_{\alpha/2 (n-1)}$,

где α - уровень значимости, равный $\frac{100 - 95}{100} = 0.05$ для 95% доверительного интервала.



Для нашей задачи требуется коэффициент Стьюдента с индексами $t_{0.05/2 (50-1)} \Rightarrow t_{0.025; 49}$.

Ниже приведен фрагмент таблицы распределения Стьюдента. В таблице первый индекс нужно найти в верхней строке – заголовок столбца, а второй (наиболее близкое значение) – в левом столбце – это название строки. Наше значение находится на пересечении столбца 0.025 и строки 50. Искомый коэффициент равен 2.0086, округляя, примем 2.01

	0.4	...	0.025	...	0.0005
1	0.3249	...	12.7062	...	636.6189
...	...	...	...	...	...
45	0.2549	...	2.0141	...	3.5203
50	0.2547	...	2.0086	...	3.4960
...	...	...	...	...	...

$$95 \% \text{ доверительный интервал} = 70 \pm 2.01 \frac{25}{\sqrt{50}}, \text{ или } 62.9 - 77.1 \text{ страниц}$$

Таким образом, менеджер может быть на 95% уверен, что средний размер работ, находящихся в его отделе – это некое конкретное значение, которое находится в диапазоне между 62.9 и 77.1 страницами. Теперь менеджер может определить минимальную и максимальную потребность в ресурсах.

6.2. Маленькие выборки

Если ваша выборка маленькая, то необходимым условием является предположение о том, что генеральная совокупность описывается нормальным распределением. Это ограничение снимается, когда выборка больше 30.

Если вы все-таки имеете дело с маленькой выборкой, постройте гистограмму и посмотрите на ее форму. Сильная асимметрия укажет на заведомо неточный результат.

Еще один плюс больших (>30) выборок: вместо распределения Стьюдента можно пользоваться нормальным распределением, т.е. вместо коэффициента $t_{\alpha/2 (n-1)}$ брать коэффициент $z_{\alpha/2}$, который не зависит от размера выборки и, следовательно, всегда одинаков для 95% доверительного интервала $z_{0.025}=1.96$. Эта величина мало отличается от той, которая была использована в примере про менеджера печатного центра.

В EXCEL для больших выборок полуширина доверительного интервала =ДОВЕРИТ(альфа, стандартное отклонение по выборке, размер выборки)
доверительный интервал =среднее по выборке ±полуширина доверительного интервала.

6.3. Доверительный интервал для доли

Иногда нас интересует оценка генеральной доли (пропорции) явлений (людей, изделий, событий) с некоторым характерным свойством. Известно, что доля явлений, в которых возникает характерное свойство, соответствует

биномиальному распределению. Однако если выборки большие, а доля особых изделий ни очень маленькая, ни слишком большая, то можно предположить, что выборочное распределение выборочной доли приблизительно нормальное.

Обозначим генеральную долю особых изделий – p , тогда чтобы воспользоваться нормальным распределением необходимо выполнение условий

$$np > 5 \quad \text{и} \quad n(1-p) > 5 \quad (\text{число } 5 \text{ не связано с уровнем значимости})$$

Если условие выполняется, то 95%-ный доверительный интервал для генеральной доли

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}},$$

где $z_{\alpha/2}$ — коэффициент нормального распределения.

Чем меньшую долю составляет интересующее нас явление, тем больше должна быть выборка.

Пример

Перед началом внедрения инноваций в крупном подразделении случайным образом выбраны 100 человек и проведен опрос. Одна из задач опроса – оценить уровень информированности людей и определить потребность в дополнительных информационных мероприятиях. Среди ста опрошенных 10 человек не смогли ответить на вопросы.

Проверим, можно ли пользоваться нормальным распределением.

$$\hat{p} = \frac{10}{100} = 0.1, \quad np = 100 \cdot 0.1 = 10 (> 5) \quad \text{и} \quad n(1-p) = 100 \cdot 0.9 = 90 (> 5)$$

Условие выполнено, размер выборки достаточен.

Для того, чтобы воспользоваться формулой $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$, нужно выбрать в таблице нормального распределения коэффициент $z_{\alpha/2}$,

Пользоваться таблицами нормального распределения несложно, как уже упоминалось, $z_{0,025} = 1.96$

Получим доверительный интервал для доли

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 0.1 \pm 1.96 \sqrt{\frac{0.1(1-0.1)}{100}} = 0.1 \pm 0.03 \quad \text{или} \quad \text{от } 0.07 \text{ до } 0.13$$

Если выборка была репрезентативной, то мы можем на 95% быть уверены, что доля не информированных людей составляет от 7 до 13%. Если руководство подразделения полагает, что 13% неприемлемая цифра для начала инноваций, то будет принято решение о дополнительных информационных мероприятиях.

В программе Excel нет подходящей функции для доверительного интервала для доли.

7. Испытание гипотез

Статистическое испытание гипотез проводится, когда по ограниченной информации (выборке) нужно определить, могут ли определенные предположения быть приняты. Например,

- Время между отказами системы составляет в среднем три месяца.
- Имеется существенное различие между средним уровнем

задержки поставок от двух поставщиков.

- Новая система планирования уменьшила затраты.

Рассмотрим пример с расфасовкой сахарного песка.

Фасовочная машина должна быть установлена так, чтобы при расфасовке каждый пакет в среднем имел определенный вес. С момента установки машины средняя наполняемость пакета вряд ли останется постоянной — отклонения от нормы будут возрастать по мере износа машины.

Производитель может организовать контроль, в котором берется выборка, вычисляются $\bar{x}$, s и доверительный интервал для веса пакета μ в генеральной совокупности. Если доверительный интервал «накрывает» требуемое значение веса, значит повода для перенастройки машины пока нет.

Можно использовать другую процедуру — испытание гипотез для оценки того, правильно ли работает машина.

Чтобы выполнить испытание, требуется две гипотезы: нулевая гипотеза, обозначаемая H_0 и альтернативная — H_1 .

Пусть машина была настроена на вес 550 г. Производитель может полагать, что машина все еще настроена правильно, и средний вес пакетов по-прежнему составляет 550 г. Его предположение составляет нулевую гипотезу и может быть записано как

$$H_0: \mu=550$$

Нулевая гипотеза всегда формулируется для утверждения того, что выборочная статистика согласуется с принятым параметром генеральной совокупности.

Эта гипотеза будет принята, если не найдется достаточно веских доказательств, свидетельствующих против нее.

Могут быть выдвинуты три варианта альтернативной гипотезы:

$$H_1: \mu>550$$

$$H_1: \mu<550$$

$$H_1: \mu\neq 550$$

Первая гипотеза предполагает, что средний вес пакетов сахара существенно больше, чем 550 г (машина «пересыпает»). Вторая гипотеза предполагает, что средний вес пакетов сахара существенно меньше, чем 550 г (машина «недосыпает»). Третья гипотеза предполагает, что вес пакетов существенно отличен от 550 г.

Из трех вариантов нужно выбрать один, исходя из условий реальной ситуации.

Первые две гипотезы требуют *односторонних* испытаний, а третья гипотеза — *двустороннего* испытания. Такие испытания проводятся на основе определенных правил и базируются на суждении лица, принимающего решения.

Какой бы результат ни был получен, мы никогда не можем определенно (на 100%) доказать или опровергнуть нулевую гипотезу. Все,

что мы можем сделать, — это или признать то, что нулевая гипотеза почти наверняка верна, или, что правильность нулевой гипотезы маловероятна. Уверенность на 100% достижима только тогда, когда измерена вся генеральная совокупность. Поэтому может случиться, что нулевая гипотеза будет отклонена, хотя она была истинной.

7.1. Испытание гипотезы: возможные результаты

Имеются четыре возможных результата при испытании гипотезы:

- Вы примете гипотезу, истинность которой покажет испытание, и она действительно была истинной (т.е. Вы пришли к правильному заключению).
- Вы отклоните гипотезу, ложность которой покажет испытание, и она действительно была ложной (т.е. Вы снова пришли к правильному заключению).
- Вы отклоните гипотезу, т.к. испытание покажет ее ложность, но она в действительности была истинной (т.е. Вы пришли к неправильному заключению). Такая ошибка относится к ТИПУ I и связана с уровнем значимости α .
- Вы примете гипотезу, т.к. испытание покажет ее истинность, но она в действительности была ложной (т.е. Вы снова пришли к неправильному заключению). Такая ошибка относится к ТИПУ II.

Вероятность отклонения правильной нулевой гипотезы, т.е. ошибки ТИПА I, должна задаваться до проведения испытания. Эта величина называется уровнем значимости α и представляет собой потенциальную ошибочность любых сделанных впоследствии выводов. Чем меньше уровень значимости, тем меньше потенциальная ошибка.


Если Вы выбираете уровень значимости $\alpha=0.05$, то другими словами Вы можете быть на 95% уверены в правильности принятого решения.

7.2. Испытание гипотезы о среднем генеральной совокупности

Существуют три типичные ситуации:

- испытание гипотезы по выборочному среднему – одна выборка

Известно, каким должно быть среднее значение генеральной совокупности. Взяв выборку, нужно проверить, не изменилось ли оно.



$$\text{Проверочная статистика } t = \frac{(\bar{x} - \mu)}{\frac{s}{\sqrt{n}}}$$

Число степеней свободы (n-1)

Условие: если выборка маленькая ($n < 30$), то распределение предполагается нормальным


Примеры задач

- Пресс делает отверстия 4 мм в металлических шайбах. Сохраняется ли правильная настройка?
- Известно, что средняя продолжительность рабочей операции составляет 50 минут. На экспериментальном участке используют новый метод. Можно ли утверждать, что он быстрее?

Компания закупает комплектующие со средним сроком службы 30 дней и имеет возможность сменить поставщика на более качественного. Взята выборка для испытаний. Можно ли полагать, что срок службы будет больше?

- испытание гипотезы по выборочным средним – независимые выборки

Имеются две выборки одинакового или разного размера, элементы которых не связаны между собой. Нужно проверить, существует ли различие между средними значениями совокупностей, из которых выборки взяты.



$$\text{Проверочная статистика } t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}},$$

$$\text{где } s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 + n_2 - 2)}$$

Число степеней свободы $(n_1 + n_2 - 2)$

Условие: если выборки маленькие ($n_1 < 30$ или $n_2 < 30$), то распределение предполагается нормальным


Дополнительное условие: $s_1 \approx s_2$

Примеры задач.

- Сравниваются два типа двигателей по количеству поломок. Есть ли основания утверждать, что один тип ломается чаще?
- Группа рабочих прошла обучение безопасным методам труда. Ведется наблюдение за этой группой и за случайно выбранной контрольной группой. Есть ли основания полагать, что рабочие, прошедшие обучение, реже нарушают правила?

- испытание гипотезы по парным данным – зависимые выборки

Имеются две выборки одинакового размера, элементы в которых составляют пары. Нужно проверить, существует ли различие между средними значениями совокупностей, из которых выборки взяты.



$$\text{Проверочная статистика } t = \frac{(\bar{x}_d - \mu_d)}{\frac{s_d}{\sqrt{n}}}$$

Число степеней свободы $(n - 1)$

Условие: если выборка маленькая ($n < 30$), то распределение предполагается нормальным.

Примеры задач

- Внесено рационализаторское предложение по ускорению технологической операции. Случайным образом отобрана группа рабочих, и измерено время выполнения каждым из них операции старым способом. Проведено обучение новому способу, и вновь измерено время выполнения операции теми же рабочими. Можно ли считать, что продолжительность операции сократилась?
- Сравнивается качество шин двух производителей. На задние колеса машин разных моделей с разными водителями случайным образом установлена одна шина первого и одна шина второго производителя. После испытания измерен износ. Можно ли считать, что качество шин двух производителей различно?

- Руководство подразделения вводит новую систему показателей для оценки работы. Проведено анкетирование случайно отобранных сотрудников, в котором их просили оценить по балльной шкале «справедливость в оценке труда» до и после изменения. Можно ли полагать, что персонал подразделения считает новую систему более справедливой?

Порядок испытания гипотез следующий:

- Определите, к какому типу относится задача
- Сформулируйте подходящие нулевую и альтернативную гипотезы
- Задайте уровень значимости
- Вычислите проверочную статистику.
- Найдите в таблице критическое значение проверочной статистики и сравните его с модулем вычисленного значения.

Критическое значение зависит от того, какое испытание проводится – одностороннее или двустороннее, от числа степеней свободы, а также от уровня значимости, который был выбран.

№	количество отчисленных с курса
1	10
2	8
3	14
4	11
5	14
6	8
7	11
8	13
9	11
10	7
11	13
12	10
13	11
14	14
15	9
16	15
17	11
18	9
19	10
20	9
21	14
22	10
23	17
24	13
25	15
26	9
27	13
28	12
29	10
30	7
31	10
32	13
33	12
34	10
35	12
36	9
37	12
38	11
39	11
40	9

- По результатам сравнения сделайте вывод о необходимости принять или отвергнуть нулевую гипотезу.

Если $|\text{проверочная статистика}| > |\text{критического значения}|$, нулевая гипотеза H_0 отклоняется

Если $|\text{проверочная статистика}| < |\text{критического значения}|$, нулевая гипотеза H_0 принимается

- Используйте результаты испытания гипотезы, чтобы принять решение относительно интересующей Вас совокупности.

Пример 7.1

Испытание гипотезы по выборочному среднему – одна выборка

Университет внедрил новую кураторскую систему, которая нацелена на то, чтобы сократить число студентов, отчисляемых с курсов. Основываясь на опыте прошлых лет, администратор полагает, что в среднем будет 12 отчислений с курса без такой системы. Через год после внедрения системы была взята выборка 40 курсов, среднее число отчислений составило 11.175 со стандартным отклонением 2.308. Администратор желает знать, действительно ли количество отчислений существенно уменьшилось после внедрения кураторской системы.

Среднее число отчислений на курс – 12, то есть $H_0: \mu = 12$

$H_1: \mu < 12$

В этом примере испытание одностороннее, потому что администратор интересуется, уменьшилось ли количество отчислений. Имеются следующие статистики выборки:

$\bar{x} = 11.175$, $s = 2.308$, $n = 40$

Уровень значимости α примем 5%.

Проверочная статистика

$$t = \frac{(\bar{x} - \mu)}{\frac{s}{\sqrt{n}}} = \frac{(11.175 - 12)}{\frac{2.308}{\sqrt{40}}} = -2.2607$$

Число степеней свободы

$$n - 1 = 40 - 1 = 39$$

Критическое значение проверочной статистики находится по таблице Стьюдента

Уровень значимости нужно найти в верхней строке – заголовок столбца, а число степеней свободы в левом столбце – название строки. Наше значение находится на пересечении столбца 0.05 и строки 40 (наиболее близкое значение к 39). Коэффициент равен 1.6839.

α	...	0.05	0.025	...
v				
1	...	6.3138	12.7062	...
...	...	...	...	...
35	...	1.6896	2.0301	...
40	...	1,6839	2.0211	...
45	...	1.6794	2.0141	...

Так как абсолютное значение проверочной статистики больше критического значения,

$$|-2,2607| > |1.6839|$$

группа с
уровнем А

№	балл
1	44
2	61
3	70
4	46
5	57
6	52
7	31
8	67
9	65
10	73
11	79
12	66
13	37
14	62
15	57
16	77
17	62
18	52
19	64
20	55
21	53
22	34
23	58
24	78
25	63
26	49
27	49
28	47
29	31
30	61
31	37
32	41
33	59
34	62
35	79
36	92
37	43
38	56
39	38
40	53

то нулевая гипотеза H_0 отвергается.

Вы можете утверждать, что, основываясь на выборочных данных, при уровне значимости 5% есть основания полагать, что среднее значение отчисленных студентов на один курс меньше 12.

Пример 7.2

Испытание гипотезы по выборочным средним – независимые выборки

Двухвыборочный t-тест с одинаковыми дисперсиями

Лектор по курсу бизнес-статистики пытается определить, действительно ли те студенты, кто ранее получили по математике уровень А (свыше 80 баллов), набирают по его предмету больше баллов, чем остальные студенты, которые имели уровень ниже А. Две выборки были отобраны случайно и получены следующие результаты

Среди имеющих уровень А по математике:

$$n_1 = 40 \quad \bar{x}_1 = \frac{\sum x}{n_1} = 56,500 \quad s_1 = \sqrt{\frac{\sum (x - \bar{x}_1)^2}{n_1 - 1}} = 14,313$$

Среди не имеющих уровень А по математике:

$$n_2 = 75 \quad \bar{x}_2 = \frac{\sum x}{n_2} = 51,320 \quad s_2 = \sqrt{\frac{\sum (x - \bar{x}_2)^2}{n_2 - 1}} = 14,943$$

Замечание. В задачах этого типа – с двумя независимыми выборками – нам придется предположить, что стандартные отклонения генеральных совокупностей σ_1 и σ_2 примерно равны.

В нашем примере стандартные отклонения выборок $s_1 = 14,313$ и $s_2 = 14,943$ достаточно близки и мы предполагаем $\sigma_1 = \sigma_2$.

Гипотезы:

$$H_0: \mu_1 = \mu_2$$

Среднее количество баллов, полученных в группе студентов с уровнем математики А существенно не отличается от среднего количества баллов, полученных в группе студентов с уровнем математики ниже А.

$$H_1: \mu_1 > \mu_2$$

В группе студентов с уровнем математики А среднее количество баллов больше, чем в группе студентов с уровнем математики ниже А..

Проведем испытание на уровне значимости 5%.

остальные

№	балл	№	балл
1	23	38	25
2	58	39	76
3	88	40	52
4	31	41	48
5	56	42	55
6	54	43	27
7	75	44	57
8	68	45	54
9	68	46	26
10	42	47	58
11	41	48	38
12	42	49	71
13	41	50	67
14	66	51	49
15	80	52	47
16	64	53	66
17	53	54	41
18	53	55	50
19	48	56	56
20	61	57	53
21	55	58	45
22	33	59	71
23	23	60	29
24	63	61	52
25	37	62	46
26	56	63	50
27	76	64	68
28	34	65	48
29	27	66	44
30	30	67	64
31	58	68	55
32	72	69	57
33	41	70	42
34	30	71	48
35	71	72	49
36	61	73	38
37	55	74	32
		75	61

Проверочная статистика

$$t = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_p^2}{n_1} + \frac{s_p^2}{n_2}}} = \frac{56.500 - 51.320}{\sqrt{\frac{216,932}{40} + \frac{216,932}{75}}} = 1,7963$$

$$\text{где } s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{(n_1 + n_2 - 2)} = \frac{(40 - 1) \cdot 14.313^2 + (75 - 1) \cdot 14,943^2}{(40 + 75 - 2)} = 216,932$$

число степеней свободы

$$n_1 + n_2 - 2 = 40 + 75 - 2 = 113$$

Критическое значение для проверочной статистики берется из таблицы Стьюдента. На уровне значимости 5% для одностороннего испытания оно равно 1.6577.

α	...	0.05	0.025	...
v	...	...	...	...
100	...	1.6602	1.9840	...
120	...	1.6577	1.9799	...
...	...	...	...	...

Значение проверочной статистики больше, чем критическое значение.

$$|1,7963| > |1.6577|$$

Поэтому, нулевая гипотеза отклоняется.

Таким образом, на уровне значимости 5% имеются убедительные свидетельства того, что среднее количество баллов, получаемых по бизнес-статистике студентами с уровнем математики А существенно отличается от среднего количества баллов, получаемых студентами с уровнем математики ниже А.

Пример 7.3

Испытание гипотезы по парным данным – зависимые выборки

№	до	после	Различие x_d
1	38	35	3
2	33	33	0
3	31	31	0
4	29	29	0
5	32	30	2
6	32	32	0
7	39	32	7
8	39	33	6
9	31	31	0
10	29	27	2
11	35	35	0
12	29	26	3
13	42	38	4
14	32	36	-4
15	27	29	-2
16	36	34	2
17	32	32	0
18	35	35	0
19	37	35	2
20	31	30	1
21	31	30	1
22	30	29	1
23	34	33	1
24	30	32	-2
25	36	34	2
26	34	31	3
27	27	29	-2
28	36	32	4
29	26	21	5
30	31	32	-1

Парный двухвыборочный t-тест

Менеджер измеряет некоторый характерный показатель работы персонала до и после изменения системы мотивации. Тридцать проверенных сотрудников показали следующие результаты.

Гипотезы: $H_0: \mu_d = 0$, где μ_d – предполагаемое среднее различие.

Нулевая гипотеза состоит в том, что нет разницы в показателе до и после изменения системы.

$$H_1: \mu_d \neq 0$$

Альтернативная гипотеза полагает, что показатель изменился после внедрения системы, не уточняя в какую сторону.

Испытание двустороннее. Проведем его на уровне значимости 5%.

Проверочная статистика

$$t = \frac{(\bar{x}_d - \mu_d)}{\frac{s_d}{\sqrt{n}}},$$

где x_d – различия, $\bar{x}_d$ – среднее различие в парах значений, s_d – стандартное отклонение различий.

Для этого примера

$$\bar{x}_d = 1.27$$

$$s_d = 2.45$$

$$\mu_d = 0$$

$$t = \frac{(1,27 - 0)}{\frac{2,45}{\sqrt{30}}} = 2.8337$$

Критическое значение берется из таблицы Стьюдента, оно равно 2,0452

α	...	0.05	0.025	...
v	...	...	...	...
28	...	1.7011	2.0484	...
29	...	1.6991	2.0452	...
...	...	...	...	...

Значение проверочной статистики больше, чем критическое значение,
 $|2,8337| > |2,0452|$

поэтому нулевая гипотеза отклоняется.

Менеджер может утверждать, что на уровне значимости 5% есть основания полагать, что показатель изменился.

Среднее значение показателя «до» $\bar{X}_1=32.8$, «после» $\bar{X}_2=31.53$, т.е. показатель уменьшился.

Обратите внимание. Менеджер мог бы попробовать использовать в этом примере **Двухвыборочный t-тест с одинаковыми дисперсиями**, считая выборки независимыми. Но при том же уровне значимости не смог бы отвергнуть нулевую гипотезу и доказать, что изменения произошли. **Парный двухвыборочный t-тест** является более сильным.

EXCEL предлагает встроенную функцию=СТЮДРАСПОБР(α ;число степеней свободы). Эта функция дает критическое значение из распределения Стьюдента для **двустороннего** испытания.

Для **примера 7.1** функция =СТЮДРАСПОБР(0,1;39)= 1,6849.

В примере 7.1 было использовано значение из таблицы 1,6839 для 40 степеней свободы.

Обратите внимание, если вы проводите одностороннее испытание, то уровень значимости в функции СТЮДРАСПОБР нужно **удвоить**.

В меню Сервис – Анализ Данных есть команды для проверки гипотез по двум выборкам

Для **примера 7.2** следует выбрать в меню Сервис – Анализ Данных - Двухвыборочный t-тест с одинаковыми дисперсиями

Его результат будет выведен как таблица

	Переменная 1	Переменная 2	
Среднее	56,5	51,32	было получено
Дисперсия	204,8717949	223,301216	
Наблюдения	40	75	число степеней
Объединенная дисперсия	216,940885		
Гипотетическая разность средних	0		
df	113		было получено
t-статистика	1,79626647		
P(T<=t) одностороннее	0,037562031		
t критическое одностороннее	1,658449946		критическое значение 1.6577 ранее было взято для числа степеней свободы
P(T<=t) двухстороннее	0,075124063		
t критическое двухстороннее	1,981179594		

Делать вывод, сравнивая проверочную t-статистику с критическим значением, все равно предстоит пользователю.

Для **примера 7.3** следует выбрать в меню Сервис – Анализ Данных - Двухвыборочный t-тест с одинаковыми дисперсиями

Его результат будет выведен как таблица

	Перемен ная 1	Перемен ная 2
Среднее	32,8	31,53333
Дисперсия	15,2	11,22299

Наблюдения	30	30	было получено t=2,8337
Корреляция Пирсона	0,782008		
Гипотетическая разность средних	0		
df	29		критическое значение по таблице 2.0452
t-статистика	2,833439		
P(T<=t) одностороннее	0,004148		
t критическое одностороннее	1,699127		
P(T<=t) двухстороннее	0,008295		
t критическое двухстороннее	2,045231		


7.3. Испытание гипотезы по выборочной доле

Существуют две типичные ситуации:

- испытание гипотезы по выборочной доле – одна выборка

Известно, какова доля особых элементов в генеральной совокупности.

Взяв выборку, нужно проверить, не изменилась ли она.



$$\text{Проверочная статистика } z = \frac{(\hat{p} - p)}{\sqrt{\frac{p(1-p)}{n}}}$$


Условие: если выборка маленькая ($n < 30$), то должно выполняться $np \geq 5$ и $n(1-p) \geq 5$

Примеры задач

- По результатам продолжительного наблюдения за технологическим процессом известно, что доля несоответствующей продукции составляет 4%. Проведена реорганизация процесса. Взята выборка, и определен % бракованных изделий. Можно ли полагать, что доля брака уменьшилась?
- По результатам многолетних наблюдений доля сотрудников, которые берут больничный лист более 5 раз в году, составляет 1%. Введена новая система профилактики заболеваний. За первый год действия новой системы показатель уменьшился до 0,9%. Есть ли основания полагать, что доля часто болеющих сотрудников снизилась?

- испытание гипотезы по выборочным долям – две выборки

Имеются две выборки, в каждой из которых есть доля особых элементов. Нужно проверить, существует ли различие между долями особых элементов в совокупностях, из которых выборки взяты.



$$\text{Проверочная статистика } z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\bar{p}(1-\bar{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

где $\bar{p}$ – доля из объединенных выборок
Условие: обе выборки большие ($n_1 > 30$ и $n_2 > 30$).

Примеры задач

- Внутренние аудиторы компании проводят в подразделении выборочную проверку документации. Некоторое количество документов признано оформленными неправильно. Аудиторы дали рекомендации по улучшению ведения документации. Следующая плановая проверка снова выявила некоторое количество неправильных документов. Можно ли полагать, что доля несоответствующих документов уменьшилась?

- Служба безопасности проводит проверку соблюдения правил внутреннего распорядка. В подразделении А численностью 500 человек выявлено 8 опоздавших, в подразделении В численностью 1000 человек – 12 опоздавших. Есть ли основания утверждать, что уровень нарушений в подразделении А выше?

Пример 7.4

Испытание гипотезы по выборочной доле – одна выборка

В поликлиниках города предлагается новая прививка от гриппа. Чтобы оценить ее эффективность, впоследствии ведется тщательный учет всех заболевших. Среди тех, кто не делал прививку (основная часть населения) заболевшие составляют 12,2 человек на 100 жителей города. Среди тех, кто сделал прививку, заболевшие составляют 7,6 человек из 100. Всего в городе сделано 512 прививок. Достаточно ли доказательств того, что люди, делающие прививку болеют гриппом реже?

Нулевая гипотеза: доля заболевших среди тех, кто делает прививки, такая же, как и среди тех, кто прививок не делает.

$$H_0: p=0,122$$

Альтернативная гипотеза: доля заболевших среди тех, кто делает прививки, меньше, чем среди тех, кто прививок не делает

$$H_1: p<0,122$$

Испытание одностороннее, проведем его на 5%-ном уровне значимости.

Проверочная статистика

$$z = \frac{(\hat{p} - p)}{\sqrt{\frac{p(1-p)}{n}}} = \frac{(0,076 - 0,122)}{\sqrt{\frac{0,122(1-0,122)}{512}}} = -3,180$$

Критическое значение для проверочной статистики находим из таблицы нормального распределения. Для уровня значимости 5% (0,05) при одностороннем испытании критическое значение приблизительно 1.645

z	0.00	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
1.4	.08076	.07927	.07780	.07636	.07493	.07353	.07214	.07078	.06944	.06811
1.5	.06681	.06552	.06426	.06301	.06178	.06057	.05938	.05821	.05705	.05592
1.6	.05480	.05370	.05262	.05155	.05050	.04947	.04846	.04746	.04648	.04551
1.7	.04457	.04363	.04272	.04182	.04093	.04006	.03920	.03836	.03754	.03673
1.8	.03593	.03515	.03438	.03362	.03288	.03216	.03144	.03074	.03005	.02938

Поскольку абсолютное значение проверочной статистики больше критического значения

$$|-3,180| < |1,645|,$$

то нулевая гипотеза отвергается. Существуют убедительные доказательства, что среди тех, кто делает прививку, доля болеющих ниже.

Пример 7.5

Испытание гипотезы по выборочным долям – две выборки

Внутренние аудиторы большой компании интересуются системой обработки счетов. Они взяли случайную выборку объемом $n_1 = 50$ счетов и проверяют их подробно. Четыре из них оказались неправильно оформленными. Тогда аудиторы предложили некоторые модификации в процедуре. Дав определенное время для внедрения новых процедур, аудиторы затем провели случайную выборку объемом $n_2 = 60$ счетов. Теперь они обнаружили три неправильных счета. Имеется ли какое-либо основание предполагать, что новые процедуры уменьшают ошибки?

Нулевая гипотеза предполагает, что две выборки случайно взяты из двух совокупностей с равными долями дефектов:

$$H_0: p_1 = p_2 = p$$

Альтернативная гипотеза предполагает, что новые процедуры сократили долю ошибок.

$$H_1: p_1 > p_2,$$

Испытание одностороннее, проведем его на 5%-ном уровне значимости.

Доля неправильных документов в выборках

$$\hat{p}_1 = \frac{4}{50} = 0.08 \quad \text{и} \quad \hat{p}_2 = \frac{3}{60} = 0.05$$

Оценка доли дефектных документов в генеральной совокупности достигается комбинированием долей двух выборок.

$$\bar{p} = \frac{4 + 3}{50 + 60} = 0.0636$$

Проверочная статистика

$$z = \frac{(\hat{p}_1 - \hat{p}_2)}{\sqrt{\bar{p}(1-\bar{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}} = \frac{(0.08 - 0.05)}{\sqrt{0.0636(1-0.0636)\left(\frac{1}{50} + \frac{1}{60}\right)}} = 0.642$$

Критическое значение такое же, как и в предыдущем примере 1,645.

Поскольку абсолютное значение проверочной статистики меньше критического значения

$$|0.642| < |1.645|,$$

то результат не существенен на 5%-ном уровне. Факты согласуются с H_0 на данном уровне значимости. У нас нет причины предполагать, что модификации в системе обработки документов сократили ошибки.

Обратите внимание. Если аудиторы увеличат выборку, то, возможно, им удастся опровергнуть нулевую гипотезу.

EXCEL предлагает встроенную функцию =НОРМСТОБР(1- α). Эта функция дает критическое значение из нормального распределения для одностороннего испытания.

Для **примеров 7.4 и 7.5** функция = НОРМСТОБР (0,95)= 1,64485.

Обратите внимание, если бы на уровне значимости 5% проводилось двустороннее испытание, то критическое значение

$$= \text{НОРМСТОБР} (0,975)= 1,959963 \approx 1.96$$

8. Статистические испытания на независимость

Если Вы проводите, например, маркетинговое исследование среди читателей газеты, Вам придется рассмотреть одновременно множество переменных. Читательская аудитория газеты сегментируется по возрасту, полу, образованию, социальному классу и т.д.

Собрав данные, Вы захотите определить, нет ли связи между переменными, и если такая связь есть, то насколько она велика. В результате можно определить целевую группу читателей газеты. Полученная информация станет основой маркетинговых решений.

В самом начале этого курса были определены два типа данных: категориальные и количественные. В зависимости от типа данных применяются два различных подхода для определения того, существует или нет взаимосвязь между переменными. Если Вы должны определить, существует ли связь между двумя количественными переменными, Вы можете вычислить величину известную как *коэффициент корреляции*. Он будет рассмотрен позднее. Если же Вам необходимо установить наличие связи между категориальными данными, то Вы можете использовать *критерий хи-квадрат* и провести *испытание на независимость*.

Пример: 8.1

Университетская администрация желает определить, существует ли различие между предпочтениями студентов (мужчин и женщин), когда они выбирают учебные курсы, не входящие в число строго

обязательных.

Использованы данные за последний год.

Курсы	Женщины	Мужчины	Всего
Бизнес	160	200	360
Естественные науки	80	70	150
Проектирование	50	20	70
Бухгалтерия	70	85	155
Маркетинг	60	90	150
Языки	50	65	115
Всего	470	530	1000

Чтобы определить, имеет ли какой-либо курс большую пропорцию мужчин- или женщин-претендентов, можно вычислить ожидаемые значения и сравнить их с наблюдаемыми значениями для каждой категории.

Если бы у мужчин и женщин не было никаких предпочтений, то в идеальном случае число ожидаемых заявлений на курс от мужчин было бы пропорционально как общему числу заявлений на этот курс, так и общему количеству мужчин. То же самое для женщин.

Ожидаемые значения могут быть рассчитаны по формуле:

$$\frac{\text{строка «всего»} \times \text{колонка «всего»}}{\text{итоговое «всего»}}$$

итоговое «всего»

Например, для первой клетки

$$\frac{360 \times 470}{1000} = 169.2$$

Ожидаемые значения для каждого курса показаны в следующей таблице. Она называется *таблицей сопряженности*. Обратите внимание, что колонка и строка «Всего» не изменились

Курсы	Женщины	Мужчины	Всего
Бизнес	169.20с	190.80	360
Естественные науки	70.50	79.50	150
Проектирование	32.90	37.10	70
Бухгалтерия	72.85	82.15	155
Маркетинг	70.50	79.50	150
Языки	54.05	60.95	115
Всего	470	530	1000

Далее мы могли бы просто посчитать в процентах различия между наблюдаемыми и ожидаемыми значениями. Но этого недостаточно, мы должны доказать, что различия неслучайны. Необходимо провести формальное статистическое испытание. Это испытание называется испытанием хи-квадрат на независимость.

8.1. Испытание хи-квадрат на независимость

Испытание хи-квадрат (χ^2) позволяет нам определять значимость статистической связи между двумя категориальными переменными. Испытание выполняется в следующей последовательности:

1) определите нулевую (H_0) и альтернативную (H_1) гипотезы. В общем случае, эти гипотезы имеют форму:

H_0 : не существует никакой связи между категориальными переменными

H_1 : существует связь между категориальными переменными

Определяя H_0 и H_1 таким образом, Вы предполагаете, что никакой связи между двумя категориальными переменными не существует, пока не доказано иное.

Обратите внимание: в формулировке гипотез не присутствует никакой параметр генеральной совокупности, такой тип испытания называется

непараметрическим.

Для нашего примера

H_0 : не существует никакой связи между полом студентов и предпочитаемыми ими курсами

H_1 : существует связь между полом студентов и предпочитаемыми ими курсами

2) выберите уровень значимости (для коммерческих решений обычно 1% или 5%). Как и ранее, уровень значимости указывает вероятность ошибки Типа I, то есть вероятность отклонения правильной нулевой гипотезы. Для нашего примера возьмем $\alpha=0,005$.

3) вычислите проверочную статистику по формуле.

$$\chi^2 = \sum \left| \frac{(\text{наблюдаемое} - \text{ожидаемое})^2}{\text{ожидаемое}} \right|,$$

где:

наблюдаемое – фактическое число претендентов на каждый курс в описанном примере.

ожидаемое – значение из таблицы сопряженности.

Важное замечание. Единственное, за чем Вы должны следить, – это чтобы ни одно ожидаемое значение не было меньше числа 5. Если Вы сталкиваетесь именно с такой ситуацией, то придется объединить маленькие курсы в категорию «Другие», так, чтобы ожидаемое значение получилось больше 5. В нашем примере самое маленькое значение – 20 (мужчины/проектирование), нам объединять строки не требуется.

В следующей таблице представлены слагаемые для χ^2 .

Курсы	Женщины	Мужчины
Бизнес	0.5002	0.4436
Естественные науки	1.2801	1.1352
Проектирование	8.8878	7.8817
Бухгалтерия	0.1115	0.0989
Маркетинг	1.5638	1.3868
Языки	0.3035	0.2691
Всего		

Первое слагаемое (0.5002) было рассчитано как $(160-169.20)^2/169.20$

Сумма всех чисел в таблице $\chi^2 = 23.8623$. Эта проверочная статистика всегда имеет положительную значение.

4) чтобы определить критическое значение статистики по таблице распределения χ^2 , нужно кроме уровня значимости, знать число степеней свободы, которое для этого испытания рассчитывается как:

$$DF = (r - 1) \times (c - 1),$$

где **r** и **c** – число строк и столбцов соответственно в таблице сопряженности. В этом примере $r=6$ (число курсов) и $c=2$ (пол претендентов), поэтому имеем 5 степеней свободы. По таблице хи-квадрат

находим

$$\chi^2_{0.05;5}=11.07$$

5) сравнение проверочной статистики с критическим значением. Если различия статистически значимы, то значение окажется в критической зоне, т.е. в области хвоста хи-квадрат распределения. Иначе говоря:

если проверочная статистика $>$ критического значения, отклоняем нулевую гипотезу H_0

если проверочная статистика $<$ критического значения, принимаем нулевую гипотезу H_0

Для хи-квадрат распределения всегда выполняется одностороннее испытание, т.к. проверочная статистика всегда положительна.

В этом примере значение проверочной статистики 23.8623 больше, чем критическое значение 11.07, следовательно, значение проверочной статистики расположено в хвосте χ^2 -распределения. Поэтому на уровне значимости 5% мы должны отклонить нулевую гипотезу H_0 .

6) В заключительной части испытания гипотезы необходимо прокомментировать результат.

В нашем примере, Вы можете сказать, что на уровне значимости 5% имеются очевидные свидетельства, чтобы предполагать существование связи между полом студента и выбираемыми курсами.

В EXCEL есть встроенная функция ХИ2ТЕСТ(). Чтобы воспользоваться этой функцией нужно заранее подготовить таблицу наблюдаемых значений и таблицу сопряженности.

Если собранные выборочные данные представлены не в форме таблицы наблюдаемых значений, то привести их к нужной форме таблицы можно, используя команду меню EXCEL: Данные – Сводная таблица.

Далее строится таблица сопряженности.

При использовании функции =ХИ2ТЕСТ(фактический интервал; ожидаемый интервал) будьте осторожны. Функция ХИ2ТЕСТ() вычисляет значение уровня значимости на котором нулевая гипотеза должна быть отклонена.

Если это значение меньше требуемого Вами уровня значимости, то Вы отклоняете нулевую гипотезу.

До сих пор, испытывая гипотезу, мы сравнивали *проверочную статистику* с ее *критическим значением*. Этот подход сложился исторически, так как для вычисления вручную он проще. Но современные компьютерные статистические программы для большинства тестов вычисляют пороговый уровень значимости, на котором нулевую гипотезу следует отклонить. Обычно эта величина называется **р-значением**. Если этот уровень меньше того, который Вы установили, то это достаточное свидетельство против нулевой гипотезы.

Обратите внимание. Правило для р-значения противоположно правилу для проверочной статистики.

Если проверочная статистика $>$ критического значения, отклоняем нулевую гипотезу H_0

Если проверочная статистика $<$ критического значения, принимаем нулевую гипотезу H_0

НО:

Если р-значение $<$ заданного уровня значимости α , отклоняем нулевую гипотезу H_0

Если р-значение $>$ заданного уровня значимости α , принимаем нулевую гипотезу H_0

Для нашего примера

функция ХИ2ТЕСТ(фактический интервал; ожидаемый интервал)=
0,000231

Это значение намного меньше принятого нами уровня значимости 5% (или в долях от единицы $\alpha=0,05$). То есть H_0 отвергается.

9. Корреляция

9.1. Связь между переменными: регрессия и корреляция

Прогнозирование является важным для любой области бизнеса. Продажи и закупки, финансы и производственные планы, – везде необходимы прогнозы.

Например, рассмотрим компанию, которая регулярно помещает рекламу на один из своих товаров в местную газету. Компания ведет записи ежемесячно о суммах денег, затраченных на рекламу и поступивших от продажи этого товара.

Если реклама эффективна, то можно предположить, что существует какая-то связь между затратами на рекламу и соответствующими ежемесячными объемами продаж. Предположим, что чем больше сумма затрат на рекламу, тем больше объем продаж (по крайней мере, в определенных пределах). Не существует теории, на основе которой мы могли бы написать уравнение, чтобы точно показать связь продаж с расходами на рекламу. Имеется ряд факторов, неразрывно связанных между собой, которые точно определяют ежемесячный объем реализации. Это такие факторы, как цена товара, цена товара-конкурента, период времени, погодные условия. Тем не менее, если расходы на рекламу являлись бы главным фактором, определяющим продажи, то знание связи между этими двумя переменными было бы очень полезным для оценки объема продаж и соответствующего планирования финансовой политики компании.

Обычно для определения связи между переменными используются

термины «регрессия» и «корреляция». Термин *«регрессия»* используется для описания *природы связи*, термин *«корреляция»* — для измерения *силы связи*.

Ясно, что регрессия и корреляция – понятия, близко связанные.

9.2. Корреляционный анализ

Для измерения силы связи между переменными существуют величины, называемые коэффициентами корреляции. Мы рассмотрим только два из них: коэффициент корреляции Пирсона и коэффициент корреляции Спирмена.

Начнем с графического представления данных.

1) Диаграмма рассеяния

Представляя графически две переменные X и Y (где X – независимая переменная и Y – зависимая переменная), мы можем:

- показать приблизительную «форму» связи между двумя переменными – это может подсказать, какую математическую модель использовать.
- показать силу связи, которая определяется сближением или рассеянием данных на графике.

Диаграммы, на которые нанесены точки, соответствующие парам значений XY , называются *диаграммами рассеяния*.


Пример 9.1

Следующие данные взяты из бизнеса «заказы по почте». Случайным образом выбраны 12 округов в Великобритании и проведено исследование, сколько тысяч каталогов разослано и сколько тысяч заказов получено.

Округ	Получено заказов, тыс.	Разослано каталогов, тыс.
A	24	6
B	16	2
C	23	5
D	15	1
E	32	10
F	25	7
G	38	15
H	18	3
I	35	11
J	34	13
K	15	2
L	32	12

Разумно было бы предположить, что количество полученных заказов зависит от количества разосланных каталогов, т.е. независимой переменной X будет число каталогов, а зависимой переменной Y – число заказов. Построим диаграмму рассеяния.

Диаграмма рассеяния



Измерение корреляции необходимо для того, чтобы оценить, насколько хорошо математическая модель «накладывается» на исходные данные.

В нашем примере «форма» связи между переменными ближе всего к линейной. Для случая линейной связи наиболее подходящей величиной (инструментом) измерения корреляции является коэффициент корреляции Пирсона.

2) Коэффициент корреляции Пирсона


Если измерения проводятся по всей генеральной совокупности, то коэффициент корреляции Пирсона обозначается буквой ρ (ро), но когда в нашем распоряжении только выборочные данные, то коэффициент корреляции для выборки обозначают буквой r (эр). Формула для коэффициента корреляции Пирсона

$$R = \frac{n \sum xy - \sum x \cdot \sum y}{\sqrt{(n \sum x^2 - (\sum x)^2) \cdot (n \sum y^2 - (\sum y)^2)}}$$


Все величины $\sum xy$, $\sum x^2$, $\sum x$, $\sum y$ и $\sum y^2$ должны быть вычислены заранее, чтобы воспользоваться формулой.

Свойства коэффициента корреляции Пирсона


1. $-1 \leq r \leq +1$ r никогда не лежит вне этого диапазона. Различные значения r указывают на различную силу связи между переменными x и y .
2. $r = +1$ совершенная линейная связь. Все точки лежат на линии, которая имеет положительный градиент (направлена вверх).




3. $r = -1$ совершенная линейная связь. Все точки лежат на линии, которая имеет отрицательный градиент (направлена вниз).




4. $r \approx 0$ случайное рассеяние, не существует линейной связи между x и y . (в регрессионной модели $b = 0$)




5. $r \approx 0$ нелинейная связь



6. $r = +0.85$ сильная линейная связь, положительный градиент



7. $r = -0.2$ слабая связь — линейная форма имела бы отрицательный градиент



В целом, чем выше значение r , тем сильнее линейная связь. Но нужно быть очень внимательным, т.к. совсем маленькая выборка может показать высокую корреляцию, но она не будет статистически значима. Напротив, бóльшая выборка даст коэффициент корреляции ниже, но он все же будет статистически значимым.

Позднее мы рассмотрим, как проверить значимость коэффициента корреляции.

Пример 9.1 продолжение

Чтобы рассчитать коэффициент корреляции, мы должны вычислить величины, входящие в формулу

Разослано каталогов — x	Получено заказов — y	$x \cdot y$	x^2	y^2
6	24	$6 \times 24=144$	$6 \times 6=36$	$24 \times 24=576$

2	16	$2 \times 16=32$	$2 \times 2=4$	$16 \times 16=256$
5	23	$5 \times 23=115$	$5 \times 5=25$	$23 \times 23=529$
...	...	...	...	...
87	307	2666	887	8633
$\Sigma x=87$	$\Sigma y=307$	$\Sigma xy=2666$	$\Sigma x^2=887$	$\Sigma y^2=8633$

Используя формулу для коэффициента корреляции, получим

$$r = \frac{n \sum xy - \sum x \cdot \sum y}{\sqrt{(n \sum x^2 - (\sum x)^2) \cdot (n \sum y^2 - (\sum y)^2)}} = \frac{12 \cdot 2666 - 87 \cdot 307}{\sqrt{(12 \cdot 887 - (87)^2) \cdot (12 \cdot 8633 - (307)^2)}} = 0.985$$

Таким образом, очень высокий коэффициент корреляции указывает на сильную линейную связь между x и y , то есть каталогами и заказами. Он также указывает, что линия регрессии, построенная по этим данным, имела бы положительный градиент.

Примечания:

- существует ложная корреляция. Можно получить высокий коэффициент корреляции при том, что не имеется никаких причинных отношений между двумя переменными.
- возможна проверка значимости коэффициента корреляции с использованием статистического вывода.
- размер выборки играет важную роль в оценке «значимости» коэффициента.

3) Ранговый коэффициент корреляции Спирмена

Коэффициент корреляции Пирсона измеряет силу связи между двумя количественными переменными X и Y . Помимо этого можно пользоваться еще одной величиной – ранговым коэффициентом корреляции Спирмена. Он используется, когда измерение по непрерывной шкале затруднительно, и более приемлемой процедурой является ранжирование. Часто это категориальные порядковые переменные.

Ранговый коэффициент корреляции Спирмена обозначается r_s и вычисляется по формуле

$$r_s = 1 - \frac{6 \cdot \sum d^2}{n(n^2 - 1)}$$

где d = различие в рангах и n = количество пар значений.

Как и коэффициент Пирсона, ранговый коэффициент лежит в пределах $-1 \leq r_s \leq +1$

Пример 9.2

Крупная туристическая компания каждый год в январе печатает список 10 наиболее популярных маршрутов за предыдущий год. То же самое делает известный женский журнал, основываясь на опросе своих читательниц.

Направление	Ранг в списке туристической компании	Ранг в списке журнала
Флорида	2	1

Канарские о-ва	5	6
Греция	3	2
Германия	4	4
Испания	6	5
Карибские о-ва	10	7
Австралия	7	9
Франция	9	10
Канада	8	8
Россия	1	3

Чтобы рассчитать r_s , мы должны вычислить различие в рангах – d и сумму их квадратов

Направление	Ранг в списке компании	Ранг в списке журнала	d	d ²
Флорида	2	1	1	1
Канарские о-ва	5	6	-1	1
Греция	3	2	1	1
Германия	4	4	0	0
Испания	6	5	1	1
Карибские о-ва	10	7	3	9
Австралия	7	9	-2	4
Франция	9	10	-1	1
Канада	8	8	0	0
Россия	1	3	-2	4
				d ² =22

Вычисление r_s дает

$$r_s = 1 - \frac{6 \cdot \sum d^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 22}{10(10^2 - 1)} = 0.867$$

Значение $r_s = 0.867$ указывает на довольно высокий уровень согласованности между рангами, представленными туристической компанией и журналом.

Коэффициент корреляции Спирмена можно применить и к количественным данным, если провести процедуру ранжирования. Например,

Данные	39	28	28	20	17	17	17	15	13
Ранги:	1	2 ½	2 ½	4	6	6	6	8	9
делим ранги 2 и 3				делим ранги 5, 6 и 7					

Ранжирование может быть проведено как по возрастанию, так и по убыванию двух переменных. После ранжирования вычисление коэффициента проводится как обычно.

Пример 9.1 продолжение

(снова пример «заказы по почте»)

Разослано каталогов	Получено заказов	Ранги		Различия	Различия ²
x	y	r _x	r _y	d = r _x - r _y	d ² = (r _x - r _y) ²
6	24	7	7	0	0
2	16	10.5	10	0.5	0.25
5	23	8	8	0	0
1	15	12	11.5	0.5	0.25
10	32	5	4.5	0.5	0.25

7	25	6	6	0	0
15	38	1	1	0	0
3	18	9	9	0	0
11	35	4	2	2	4
13	34	2	3	-1	1
2	15	10.5	11.5	-1	1
12	32	3	4.5	-1.5	2.25
					$\Sigma d^2 = 9.0$

Таким образом

$$r_s = 1 - \frac{6 \cdot \Sigma d^2}{n(n^2 - 1)} = 1 - \frac{6 \cdot 9}{12(12^2 - 1)} = 0.9685$$

Высокая положительная корреляция указывает на сильную связь между рангами X и Y. (сравните с $r = 0.985$, вычисленным ранее).

В EXCEL для вычисления коэффициента корреляции Пирсона существуют две функции:

КОРРЕЛ(массив значений 1;массив значений 2)

ПИРСОН(массив значений 1;массив значений 2)

10. Простая линейная регрессия

В примере «заказы по почте» мы обнаружили, что количество заказов возрастает при увеличении числа разосланных каталогов. Более того, мы пришли к выводу, что уместно предположить существование именно линейной связи.

10.1. Понятие простой линейной модели регрессии

Если связь между двумя переменными действительно следует описывать при помощи прямой линии, то для каждой пары (x, y) из генеральной совокупности мы можем записать

$$y = \alpha + \beta x + \varepsilon,$$

где y – зависимая переменная

x – независимая переменная


α – пересечение линии с осью y

β – угол наклона линии

ε – остаток

Последняя величина ε появляется потому, что идеальные линейные отношения вряд ли имеют место. Остаток ε учитывает случайные колебания относительно линии, но мы полагаем, что на всем диапазоне данных сумма остатков стремится к нулю.

Графически мы имеем:



На практике нам приходится оценивать параметры α и β , используя только доступные выборочные данные.

Линия регрессии по выборочным данным имеет вид

$$\hat{y} = a + b x$$

где $\hat{y}$ – оценка значения переменной y

a – оценка параметра α

b – оценка параметра β

Важно понять, что a и b зависят от того, какие данные оказались в выборке, но вычислив a и b , мы сможем сделать статистический вывод относительно α и β – параметров генеральной совокупности.

10.2. Оценка выборочной линии регрессии


1) на глаз

Первый способ состоит в том, чтобы наложить прямую линию на диаграмму рассеяния и затем определить параметры графически. Это, конечно, субъективно, но можно немного поправить дело, если нанести на диаграмму дополнительную точку – среднее арифметическое $\bar{x}$ и $\bar{y}$, т.е. центральную точку. Прямая линия должна проходить через нее.

Для примера про почту

$$\bar{x} = \frac{\sum x}{n} = \frac{87}{12} = 7.5 \quad \text{и} \quad \bar{y} = \frac{\sum y}{n} = \frac{307}{12} = 26.6$$

Диаграмма рассеяния



Из графика имеем

$$b = \frac{8.5}{5} = 1.7$$

(Треугольник может быть построен произвольно)


$$a = 13.2 \text{ (приблизительно).}$$

Таким образом, оценочная линия регрессии: $\hat{y} = 13.2 + 1.7x$

2) методом наименьших квадратов

Имея компьютер, легче воспользоваться формулами, чем проводить графические построения.

Классический подход – использовать метод наименьших квадратов. Идея состоит в том, чтобы построить «лучшую» линию, которая минимизирует сумму квадратов расстояний $d_1, d_2, d_3, \dots$ от фактических данных до линии.



То есть минимизируется величина $\sum (y - \hat{y})^2$, где $d_i = y_i - \hat{y}_i$
 Можно доказать что, параметрами искомой линии будут

$$b = \frac{n\sum xy - \sum x \cdot \sum y}{n\sum x^2 - (\sum x)^2} \quad \text{и} \quad a = \bar{y} - b \bar{x}$$

Все величины, входящие в формулу, нужно рассчитать по выборочным данным.

Проиллюстрируем это все на том же примере «заказы по почте»

Пример 9.1 продолжение

x	y	x y	x ²
6	24	6 × 24=144	6 × 6=36
2	16	2 × 16=32	2 × 2=4
5	23	5 × 23=115	5 × 5=25
...	...	...	...
87	307	2666	887
$\sum x=87$	$\sum y=307$	$\sum xy=2666$	$\sum x^2=887$

Подставляя значения в формулу, получим

$$b = \frac{n\sum xy - \sum x \cdot \sum y}{n\sum x^2 - (\sum x)^2} = \frac{12 \cdot 2666 - 87 \cdot 307}{12 \cdot 887 - 87^2} = 1.72$$

и

$$a = \bar{y} - b \cdot \bar{x} = 25.6 - 1.72 \cdot 7.25 = 13.13$$

Таким образом, по методу наименьших квадратов оценочная линия регрессии: $\hat{y} = 13.13 + 1.72 x$

На практике трудоемкие расчеты не нужно выполнять вручную. Любые пакеты статистических программ содержат соответствующие функции для построения линии регрессии.

Примечание. Мы приняли простую линейную модель регрессии. В действительности, вероятно, имеются и другие факторы, которые влияют на продажи, а не только число разосланных каталогов.

3) прогноз: интерполяция или экстраполяция

Построенная оценочная линия регрессии может использоваться для целей прогнозирования.

Мы *интерполируем*, когда оцениваем значение независимой переменной y для данного значения x , если x находится в пределах диапазона выборочных данных. Например, самое маленькое значение x – 1, и самое большое – 15; следовательно, выбор любого значения x в этом диапазоне для предсказания значения y называется *интерполяцией*.

Например, для

$$x = 8 \text{ (8000 разосланных каталогов)}$$

получим

$$\hat{y} = 13.13 + 1.72 \cdot 8 = 27 \text{ (то есть 27000 полученных заказов)}$$

$\hat{y}$ – это оценочное значение. Можно оценить также и вариацию значений вокруг линии регрессии. Для этого существуют формулы, но в этом курсе не рассматриваются.

Мы *экстраполируем*, когда значение y предсказывается для значения x , лежащего вне диапазона 1 - 15. *Экстраполяция* предполагает, что линейная тенденция все еще имеет силу в интересующей нас области.

Необходимо осторожно оценивать вероятность линейной связи вне данного диапазона x

Например, для

$$x = 17 \text{ (17000 разосланных каталогов)}$$

получим

$$\hat{y} = 13.13 + 1.72 \cdot 17 = 42 \text{ (то есть 42000 полученных заказов)}$$

И для интерполяции, и для экстраполяции мы должны при помощи корреляционных коэффициентов оценивать насколько «хороша» линейная связь между переменными.

4) коэффициент детерминации

Есть еще одна величина, которая может использоваться – *коэффициент детерминации*, обозначаемый r^2 (коэффициент корреляции Пирсона в квадрате). Коэффициент детерминации показывает долю общей дисперсии зависимой переменной y , которая объясняется вариацией независимой переменной x . Чем ближе r^2 к единице, тем лучше регрессионная модель.

Для нашего примера «заказы по почте» коэффициент детерминации

$$r^2 = 0.985^2 = 0.970$$

Это означает, что линейная модель объясняет 97% вариации заказов, 3% – не объясняет, эта часть вариации обусловлена другими факторами, а не количеством каталогов.

В EXCEL для вычисления коэффициентов простой линейной регрессии есть формулы:

параметр a

ОТРЕЗОК(значения y ; значения x)

параметр b

НАКЛОН(значения y ; значения x)

Для предсказания значений на основе линейной регрессии существует функция

ПРЕДСКАЗ(x ; значения y ; значения x)

11. Анализ линейной регрессии: статистический вывод и предположения

Компьютерные программы рассчитают для Вас модель линейной регрессии (часто ее называют в программах линией тренда), не обращая внимания на то, как лежат точки вокруг линии. Вам придется решать, как интерпретировать результаты. Недостаточно просто найти коэффициенты регрессии, нужно проверить их значимость. Для этого используются методы статистического вывода.

Если проверка подтверждает значимость модели, то мы можем использовать ее для прогнозирования. Но даже после этого остаются некоторые предположения, которые должны быть проверены, перед тем как окончательно доверять регрессионной модели.

11.1. Статистический вывод в регрессионном анализе

1) испытание значимости коэффициента корреляции Пирсона (ρ)

Вывод о линейности связи в генеральной совокупности зависит от размера выборки. Так, если мы получили коэффициент корреляции Пирсона, например, 0.90, который рассчитан для выборки из шести единиц, и сравниваем его с таким же значением, которое было рассчитано для выборки из двадцати единиц, то во втором случае мы более уверены, что связь в генеральной совокупности — линейная. Шанс получения выборочной совокупности, в которой связь линейна, из генеральной совокупности, в которой связь на самом деле не линейна, уменьшается по мере увеличения размера выборки.

Процедура проверки гипотезы:

$H_0: \rho = 0$ (Между переменными x и y не существует линейной связи, иначе говоря, независимая переменная x не помогает в предсказании значений y)

$H_1: \rho \neq 0$ (Между переменными x и y существует некая линейная связь, x помогает в прогнозировании y .)

Проверочная статистика:

$$t = \sqrt{\frac{r^2(n-2)}{1-r^2}}$$

Испытание двустороннее. Число степеней свободы равно $(n-2)$, n — число пар значений выборки. Критическое значение берется из таблицы Стьюдента.

Вернемся к примеру «заказы по почте»

Пример 9.1 продолжение

Мы получили значение коэффициента корреляции $r=0,985$. Тогда значение критерия:

$$t = \sqrt{\frac{r^2(n-2)}{1-r^2}} = \sqrt{\frac{0.985^2(12-2)}{1-0.985^2}} = 18.05$$

Число степеней свободы: $(12-2) = 10$. Уровень значимости примем 5%.

По таблицам находим значение $t_{0.025;10} = 2.228$.

Абсолютное значение проверочной статистики больше критического значения

$$|18.05| > |2.228|$$

Поэтому мы отклоняем H_0 на 5%-ном уровне значимости и выбираем гипотезу H_1 , т.е. мы в праве предположить, что коэффициент корреляции в генеральной совокупности не равен нулю, и что между каталогами и заказами существует линейная связь. Этот результат можно было предвидеть, учитывая высокое значение коэффициента корреляции r .

Если бы испытание показало, что нулевую гипотезу ($\rho = 0$) нельзя отклонить, то вместо линейной регрессии для прогнозирования нам пришлось бы использовать просто среднее арифметическое $\bar{y}$.

2) испытание коэффициента регрессии (β)

Выполняется следующим образом:

$H_0: \beta = 0$ (Между переменными нет линейной связи, и x не помогает в прогнозировании y)

$H_1: \beta \neq 0$ (Существует линейная связь и x помогает в прогнозировании y)

Двустороннее испытание.

Проверочная статистика имеет вид

$$t = \frac{b^2(n-2)(n\sum x^2 - (\sum x)^2)}{n(\sum y^2 - a\sum y - b\sum xy)}$$

Значение t следует брать из таблиц t -распределения Стьюдента с $n-2$ степенями свободы и требуемым уровнем значимости.

Обратите внимание. Для простой линейной регрессии проводят испытание значимости либо для β , либо для ρ .

11.2. Предположения при анализе регрессии

Чтобы пользоваться выводами, сделанными в ходе анализа регрессии, придется подтвердить некоторые предположения. Если они нарушены, то наш анализ не имеет силы. Посмотрим что это за предположения, и как их проверить практически.


1) диаграмма рассеяния для остатков

Остаток e_i определен как различие между наблюдаемым y_i и предсказанным $\hat{y}_i$ значением зависимой переменной

$$e_i = y_i - \hat{y}_i$$

Например, если формула линии регрессии была определена по выборке как $\hat{y}_i = 3 + 2x_i$, то для $x_i = 4$, имеем предсказанное значение $\hat{y}_i = 11$, хотя в выборке y_i могло иметь другое значение.


Мы можем оценить пригодность линейной модели регрессии, построив график рассеяния для остатков. Положение точек должно носить случайный характер. Если линейная модель не подходит, то рисунок покажет это очень четко.



Иногда, даже в тех случаях, когда коэффициент линейной корреляции значим, одного взгляда на график рассеяния остатков достаточно, чтобы убедиться, что криволинейная модель подойдет больше. По существу, правый рисунок – это отклонения от линии регрессии в увеличенном масштабе.

2) нормальность остатков

Значение y должно быть нормально распределено для каждого значения x . Даже если это не совсем строго соответствует истине, важно, чтобы распределение было хотя бы разумно симметрично. Тогда отклонение от нормальности не будет серьезно воздействовать на выводы, сделанные относительно линии регрессии, и ее коэффициентов.




Оценка может быть сделана на глаз. Лучше всего построить гистограмму остатков. Ее форма должна напоминать колокол. Но и диаграмма рассеяния остатков может быть полезной, точки на всем протяжении должны располагаться примерно симметрично.

3) равномерность остатков

Вариация y должна быть постоянна для всех значений x . Это значит, что отклонения y от линии регрессии при маленьких x должны быть примерно такими же, как и для больших значений x . Это предположение важно для применения метода наименьших квадратов, и если оно не выполняется нужно проводить преобразование независимой переменной x .

Оценка может быть сделана на глаз, нужно построить диаграмму рассеяния остатков.

Рисунок ниже показывает эффект неравномерного распределения остатков, они возрастают при увеличении x .



Единственным способом продолжать статистический анализ в таком случае является трансформация данных (часто используются логарифмы значений x) до тех пор, пока график остатков не покажет случайное рассеяние точек относительно $e=0$.

4) независимость остатков

Нужно следить, нет ли какой-то формы зависимости между остатком и

независимой переменной. Особенно это относится к данным, которые собираются через определенные периоды времени. Такой анализ может помочь выявить, например, сезонные колебания.

Оценивается путем построения диаграммы рассеяния остатков. Должно наблюдаться случайное расположение точек без каких-либо периодических искажений.

Для получения модели простой линейной регрессии в EXCEL можно использовать команду меню Сервис-Анализ данных-Регрессия. Вы получите несколько таблиц, одна из которых будет содержать значения коэффициентов регрессии и проверку их значимости.

Для примера «заказы по почте»


	Коэффициенты	...	t-статистика	P-Значение
Y-пересечение	13,12748	...	16,27835	1,59E-08
Переменная X	1,718049	...	18,31621	5,06E-09

коэффициент а

коэффициент b

p-значение должно быть меньше 0.05, для уровня значимости 5%

Если в диалоговом окне поставить флажок в окошке «График остатков», то Вы получите диаграмму рассеяния остатков.



По ней вы можете оценить

- 1) нормальность остатков – точки приемлемо симметричны относительно горизонтальной оси.
- 2) равномерность остатков – не наблюдается явной тенденции увеличения или уменьшения абсолютного значения остатков с возрастанием x. (Есть некоторые сомнения).
- 3) независимость остатков – не наблюдается каких-либо характерных искажений.

11.3. Множественная регрессия

Выбранная независимая переменная вряд ли является единственным фактором, который влияет на зависимую переменную. В большинстве случаев мы можем говорить о нескольких факторах, влияющих на зависимую переменную.

Множественная регрессия для прогноза зависимой переменной использует более чем одну независимую переменную.

Например, риэлтеры прогнозируют цену продажи квартиры, принимая во внимание площадь, качество и возраст постройки, удобство места и т.д. Реальная цена сделки может отличаться от прогнозируемой.

Кинотеатр может прогнозировать число зрителей, учитывая рейтинг фильма, день недели, погоду, время сеанса, наличие конкурентных фильмов.

Построим модель, предполагая, что все переменные независимы друг от друга, а между независимыми и зависимой переменной существует линейная связь.

В этом случае мы будем иметь не пару, а набор значений $(x_1, x_2, \dots, x_n, y)$, соответствующий каждому из наблюдений. Общий вид данных можно представить так:

Наблюдение	Независимые переменные				Зависимая переменная
	X_1	X_2	...	X_{1k}	Y
1	X_{11}	X_{12}	...	X_{1k}	Y_1
2	X_{21}	X_{22}	...	X_{2k}	Y_2
...	...	...	...	...	...
i	X_{i1}	X_{i2}	...	X_{ik}	Y_i
...	...	...	...	...	...
n	X_{n1}	X_{n2}	...	X_{nk}	Y_n

По аналогии с простой линейной моделью регрессии, можно записать:

$$y = \alpha + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \varepsilon$$

Как и в случае простой линейной регрессии, мы получаем по выборке оценки α , β_1 , β_2 , ..., β_n и получаем уравнение регрессии

$$\hat{y} = a + b_1 x_1 + b_2 x_2 + \dots + b_n x_n.$$

Для анализа множественной регрессионной модели используются те же предположения, что и в случае простой регрессии: независимая переменная не имеет связи с другой независимой переменной, их дисперсии одинаковы, ошибки независимы друг от друга. Но в данном случае они ведут к сложным вычислениям.

Далее мы определим шаги, которые необходимо предпринять.

Шаг 1. подготовка исходных данных. Он предполагает выяснить, как зависимая переменная может быть связана с каждой из независимых переменных, посчитав коэффициенты корреляции r для всех пар переменных. Это даст нам возможность определить, связаны ли x и y линейно или нет, независимы ли x_i между собой. Если две независимые переменные имеют

высокую корреляцию между собой, то мало вероятно, что они обе должны быть включены в окончательную модель.

Шаг 2. определение всех статистически значимых моделей. Модель имеет силу в том случае, если существует значимая линейная связь между y и всеми x и если каждый коэффициент регрессии b отличается от нуля. Мы можем оценить значимость модели в целом, используя F-критерий. Кроме того, мы должны использовать t-критерий для каждого коэффициента регрессии, чтобы определить, значимо ли он отличается от нуля. Если коэффициент регрессии не значимо отличается от нуля, то соответствующая независимая переменная не помогает в прогнозе и модель не имеет силы.

Полное рассмотрение всех возможных моделей является длительной процедурой и используется редко. Чаще для получения множественной регрессии пользуются одним из следующих методов.

Множественную регрессию получают, расширяя круг переменных. Мы начинаем с построения простых регрессий для каждой из независимых переменных, выбираем лучшую из них (с наивысшим коэффициентом корреляции) и добавляем вторую переменную. Этот метод получения множественной регрессии называют прямым.

Обратный метод начинается с исследования модели, включающей все независимые переменные. Переменная, которая дает наименьший вклад, исключается. Если же полученная модель неверна, исключается еще одна переменная и т.д. после каждого исключения нужно проверять, не была ли исключена значимая переменная.

Может быть несколько значимых моделей и каждая из них иметь огромное значение.

Шаг 3. Выбор лучшей модели из всех значимых моделей. Для того, чтобы сделать выбор, проверяют значения коэффициента детерминации.

Коэффициент множественной корреляции (R) – отношение вариации y , объясняемое моделью, к общей вариации (близость между реальными и прогнозируемыми значениями).

Коэффициент детерминации R^2 – процент вариации, объясняемый моделью (независимыми переменными, входящими в модель).

Пример

Крупная авиакомпания изучает, кто является ее пассажирами и от каких факторов зависит спрос на билеты. Была взята выборка 200 пассажиров. Каждый пассажир отвечал на вопросы о том,

- сколько раз он летал рейсами этой компании за последний год;
- какова цель его полетов (бизнес или личные цели);
- что он ценит больше: комфорт, точность или частоту рейсов (только один ответ);

также пассажира просили указать его

- пол,
- возраст,
- годовой доход.

Полученные данные сведены в таблицу, фрагмент которой вы видите.

Файл с полными данными будет выдан на занятии в компьютерном классе.

число полетов за последний год	пол	цель полета	самая важная характеристика	годовой доход, тыс.\$	возраст
1	женщина	бизнес	комфорт	22	35
3	мужчина	бизнес	комфорт	51	35
2	мужчина	бизнес	частота рейсов	18	42
2	мужчина	личные цели	точность	22	25
3	мужчина	личные цели	частота рейсов	36	28
3	мужчина	личные цели	точность	31	34

Построим сначала простую регрессионную модель, используя Excel.

До построения регрессионной модели мы должны предварительно оценить, какая из переменных в большей степени влияет на интересующий показатель – количество полетов. Для этого построим корреляционную таблицу для количественных переменных: число полетов, годовой доход, возраст.

Обратите внимание, что все столбцы переменных, для которых проводятся вычисления, должны быть рядом. Перенесите столбцы «годовой доход» и «возраст» к столбцу «число полетов». Выберите команду Сервис⇒Анализ данных. В списке Инструменты анализа выберите значение Корреляция. В появившемся диалоговом окне нужно ввести интервал данных и поставить отметку, что в первой строке находятся названия переменных. На новом листе мы получим таблицу. На пересечении строки и столбца – значение коэффициента корреляции между переменными.

	число полетов	год. доход, тыс.\$	возраст
число полетов	1		
год. доход, тыс.\$	0,83527372	1	
возраст	0,077180676	0,031603056	1

Коэффициент корреляции между числом полетов и годовым доходом

Самый высокий коэффициент корреляции между переменными «число полетов» и «годовой доход», он составляет 0,835, что говорит о наличии сильной связи между числом полетов и доходами пассажира.

Коэффициенты получились значимы на уровне 1%. С помощью Excel это можно проверить, используя. Сервис⇒Анализ данных⇒Парный двухвыборочный тест для средних. Комментарии по использованию этих функций были даны в Главе 7.

Используя количественную переменную «годовой доход», построим простую регрессионную модель.

Для этого выберите команду Сервис⇒Анализ данных.

На экране раскроется диалоговое окно. В списке Инструменты анализа выберите значение Регрессия.

В поле Входной интервал Y введите адреса ячеек, в которых находятся значения зависимой переменной (в нашем случае – число полетов за год). В поле Входной интервал X для множественной регрессии нужно ввести весь диапазон, где находятся значения независимых переменных. Так как мы пока строим простую регрессионную модель, выберем столбец «годовой доход», это переменная X.

Выберите, куда поместить результаты (по умолчанию предлагается отдельный лист) и нажмите «ОК». Получим **Модель I**

В отчете Excel содержится большое количество параметров. Рассмотрим некоторые из них.

Для оценки модели используем содержащийся в первой таблице квадрат коэффициента регрессии – R^2 .

Модель I	
Регрессионная статистика	
Множественный R	0,83527372
R-квадрат	0,697682187
Нормированный R-квадрат	0,694597311
Стандартная ошибка	1,138482038
Наблюдения	100

R^2 достаточно близок к единице. $R^2=0.698$, это означает, что 69,8% вариации числа полетов объясняются вариацией доходов

Коэффициенты уравнения регрессии и их оценки возьмем из другой таблицы. Здесь приведен ее фрагмент. Он аналогичен таблице из примера в главе 7.

	Коэффициенты	t-статистика	P-Значение
Y-пересечение	-0,092102589	-0,366249038	0,71496874
год. доход, тыс \$	0,086954683	15,03868928	3,34388E-27

это коэффициент а

это коэффициент b

Получена модель $y = -0.0921 + 0.0869x$

Коэффициент $a = -0.0921$, константа, его значимость не оценивается. Для модели важен коэффициент b (вторая строчка). Для его оценки используем Р-значение. Оно намного ниже, чем 0,01. Т.е. модель точно значима на уровне 1%.

На самом деле уровень значимости $3.34 \times 10^{-27} \times 100\% = 3.34 \times 10^{-25}$. (Это очень высокий уровень значимости)

Интерпретация модели может быть такой: если годовой доход пассажира увеличивается на тысячу долларов, количество полетов увеличивается на 0,0869.

Если отдел продаж предполагает, что модель с одной переменной слишком проста, то можно построить более сложную модель. Добавим еще одну переменную – возраст пассажира. Точно также, используем Сервис⇒Анализ данных⇒Регрессия. Получаем новый набор таблиц для **Модели II**.

Модель II	
Регрессионная статистика	
Множественный R	0,841678
R-квадрат	0,708421
Нормированный R-квадрат	0,702409
Стандартная ошибка	1,123827
Наблюдения	100

$R^2 = 0.708$, модель объясняет 70.8 вариации количества полетов

Мы видим, что новая модель не хуже предыдущей, имеет смысл продолжить построение.

Рассмотрим значения коэффициентов и их оценки.

	Коэффициенты	t-статистика	P-Значение
Y-пересечение	-0,8006	-1,78075	0,078084
год. доход, тыс.\$, x_1	0,087296	15,28692	1,4E-27
возраст, x_2	0,016737	1,890131	0,061726

коэффициент а

Р-значение для x_1 (годовой доход) меньше, чем 0,01. ОК

коэффициент b_1

коэффициент b_2

Р-значение для x_2 (возраст) больше 0,05, следовательно коэффициент незначим на уровне 5%

Мы получили модель, один из коэффициентов которой – b_2 при x_2 (возраст), значим на уровне $0,0617 \times 100\% \approx 6,2\%$. То есть, это вероятность того, что коэффициент неверный, потому что нам не повезло с теми 200 пассажирами и выборка была неудачной. Пользоваться или нет этой моделью, пусть решает отдел продаж. Чтобы принять такое решение, нужно считать цену ошибки при принятии решения на основе этих данных. Например, решения о размещении рекламы для старших возрастных групп.

У нас есть еще две переменные – пол и цель полетов. Обе переменные качественные. Попробуем включить в модель переменную «пол». Она принимает только два значения. Когда значений только два, можно провести прямую замену значений переменной. Заменяем значения категориальной переменной «пол» (мужчина, женщина) на количественные значения: мужчина=1, женщина=0. Для замены удобно использовать функцию ЕСЛИ (мужчина; 1, женщина; 0) Внесем изменения в таблицы данных (столбцы со значениями независимых переменных должны следовать без перерывов), проведем вычисления.

Повторим Сервис⇒Анализ данных⇒Регрессия. Получим модель III. Она включает две переменные x_1 – годовой доход и x_2 – пол. Эта модель объясняет 71.2% вариаций количества полетов. Она лучше чем первая модель, но ненамного.

Модель III	
Регрессионная статистика	

Значение R^2 стало чуть лучше, чем в модели I

Множественный R	0,84407
R-квадрат	0,712454
Нормированный R-квадрат	0,706525
Стандартная ошибка	1,116029
Наблюдения	100

Оценим значимость коэффициентов:

	Коэффициенты	Стандартная ошибка	t-статистика	P-Значение
Y-пересечение	-0,50911	0,309303	1,646000958	0,10300007
год. доход, тыс.\$, x_1	0,086576	0,005671	15,26762404	1,53207E-27
Пол, x_2	0,57559	0,257851	2,23225616	0,027898621

а

Коэффициент b_1 значим на уровне 1%, P-значение меньше 0.01

b_1 b_2

Коэффициент b_2 значим на уровне 2,8 %

Получена модель $y = -0,509 + 0,086x_1 + 0,575x_2$, где $x_2 = 1$ для мужчин и $x_2 = 0$ для женщин. Она значима на уровне 2,8%.

Интерпретация результата может быть такой: при одном и том же годовом доходе мужчина делает на 0,58 поездки в год больше, чем женщина.

Для каждой задачи может быть несколько моделей, отличающихся составом независимых переменных. Чтобы подобрать для них переменные, наилучшим образом помогающие прогнозировать интересующее значение, используют корреляционную таблицу. Из всех возможных моделей рассматривают те, которые включают только значимые переменные. Основным критерием выбора модели служит значение R^2 .

12. Анализ временных рядов

Условия развития бизнеса с течением времени меняются, поэтому менеджеры должны прогнозировать, какое влияние эти изменения окажут на их компанию. Разработано большое количество методов, все они преследуют одну и ту же цель – предсказать события, которые произойдут в будущем, чтобы учесть их при разработке планов и стратегии развития компании. Например, для руководства компании важен прогноз объема продаж, цен на продукцию – они определяют план производства, потребности в оборудовании, персонале.

В данном разделе методы прогнозирования рассматриваются на примере анализа временных рядов. Временным рядом называют ряд значений, взятых за временной период.

Метод анализа временных рядов позволяет предсказать значение числовой переменной на основе ее прошлых и настоящих значений. Примером временного ряда могут быть ежедневные котировки акций на

бирже, ежегодные доходы от продаж какой-либо компании, еженедельные потери от простоев, ежемесячное незапланированное изменение численности персонала.

12.1. Компоненты анализа

Основное предположение, которое лежит в основе анализа временных рядов, состоит в следующем: факторы, влияющие на исследуемый объект в настоящем и прошлом, будут влиять на него и в будущем. Важная часть анализа временного ряда – это выбор подходящей модели прогнозирования. Основным инструментом этого анализа может быть график временного ряда или гистограмма. Из графика можно увидеть характеристики данных или компоненты ряда, которые и определяют выбор модели.

Компоненты временного ряда описаны в таблице:

Таблица 12.1

Компоненты временного ряда

Компоненты временного ряда	Определение	Причины	Продолжит. влияния
Тренд	Описывает долговременное возрастание и убывание данных	Изменения технологии, населения, благосостояния, рыночных цен	Несколько лет
Сезонные колебания	Описывает четко выраженные периодические колебания, проявляющиеся ежегодно	Погодные условия, социальное поведение, религиозное поведение	В течение года (возможно также, месяц или квартал)
Циклические колебания	Повторяющиеся колебания, имеющие четыре фазы: пик (процветание), спад (рецессия), дно (депрессия), подъем (восстановление или рост)	Взаимодействие многочисленных факторов, влияющих на экономическую активность	Как правило, с переменной интенсивностью на протяжении 2-10 лет
Случайные колебания	Случайные колебания временного ряда, возникающие после учета систематических эффектов	Случайные колебания данных или непредвиденные события, например, забастовки, ураганы и наводнения	Кратковременные и однократные

На рис. 12.1 приведен график, показывающий объемы продаж автомобилей компании Ford Motor Company в течение 1991-1997 года в млрд. долларов.



Рис.12.1. График временного ряда поквартальных продаж автомобилей Ford Motor Company в течение 1991-1997 года

Видно, что в течение года происходят выраженные поквартальные колебания продаж, но при этом сохраняется общая тенденция к росту. Объемы продаж, как правило, достигают пика во втором квартале, о чем свидетельствует график временного ряда соответствующих данных. Затем они нарастают в течение последующих трех кварталов. Поскольку сезонный сценарий не повторяется в точности каждый год, ряд характеризуется некоторой циклическостью и нерегулярностью (включает случайную компоненту).

Результаты анализа тренда и сезонности представлены на рис. 12.2. соответствующий тренд выражается прямой линией, сезонный индекс повторяется каждый год, циклический компонент непостоянен, а нерегулярный компонент носит в основном случайный характер. Все компоненты показаны в том же масштабе, что и исходный ряд.

Точность прогнозирования с использованием временного ряда зависит от способности идентифицировать компоненты ряда в наборе данных. Эта информации может быть использована по-разному, в зависимости от цели прогноза, от того, как он будет использоваться. Методы, которыми компоненты ряда объединяются в модель, могут быть различными. Наиболее общими моделями являются аддитивная и мультипликативная.




Рис.12.2 График поквартальных продаж с разбивкой на четыре базовых компонента

12.2. Классические модели

Большая часть временных рядов лучше всего описывается классическими моделями, линейные модели, более понятные встречаются редко.


Аддитивная модель: $Y_t = T_t + C_t + S_t + R_t$

Мультипликативная модель: $Y_t = T_t \times C_t \times S_t \times R_t$

Обе модели имеют свои достоинства, и какую из них лучше использовать, зависит от набора данных. Есть только общие принципы, показывающие ситуацию, которой более соответствует та или иная модель.

Аддитивная: вариации значений временного ряда имеют постоянную величину. То есть, значение меняется в течение определенного времени в одном и том же интервале.

Мультипликативная: значения меняются с течением времени пропорционально некоторой величине.



Аддитивная модель

Мультипликативная модель

12.3. Идентификация тренда

Один из важнейших аспектов анализа временных рядов – это установление долговременных изменений, то есть, характерного поведения временного ряда на большом интервале времени. Сезонность и случайные компоненты усложняют эту задачу. Чтобы установить основное направление или тренд, мы стараемся сгладить сезонную и случайную компоненты.

В тренд обычно включают циклическую компоненту. Циклические изменения – это часть тренда, они часто определяют поведение всего временного ряда, но при измерениях ее трудно выделить и самостоятельно.

Существует много методов сглаживания временных рядов.

Контрольные вопросы

1. Каким образом количественные переменные можно перевести в категориальные?
2. Какие основные способы существуют для графического представления количественных данных?
3. В каких случаях используются выборочные исследования?
4. При каком распределении данных мода, медиана и среднее арифметическое совпадают?
5. Какие величины используются для определения разброса данных внутри набора?
6. Что такое статистический вывод?
7. Назовите четыре возможных результата при испытании гипотез.
8. Каким образом можно определить значимость статистической связи между двумя категориальными переменными?
9. Что такое регрессия и корреляция?
10. Математически опишите линию регрессии по выборочным данным.
11. Приведите примеры применения множественной регрессии.
12. Какой основной инструмент применяется для анализа временного ряда?