

Лекция 3. Предварительная обработка данных.

Предварительная обработка данных: очистка, восстановление пропущенных значений, обогащение.

Процессы понимания данных:

- Собрать исходные данные
- Описать данные
- Исследовать данные
- Проверить качество данных

Процессы подготовки данных

- Отобрать данные
- Очистить данные
- Сделать производные данные
- Объединить данные
- Привести данные в нужный формат

Основные понятия:

Переменная - свойство или характеристика, общая для всех изучаемых объектов, проявление которой может изменяться от объекта к объекту

Значение переменной является проявлением признака

Переменные могут являться **числовыми данными либо символьными**

Генеральная совокупность - вся совокупность изучаемых объектов, интересующая исследователя

Параметры - числовые характеристики генеральной совокупности

Статистики - числовые характеристики выборки

Гипотеза - частично обоснованная закономерность знаний, служащая либо для связи между различными эмпирическими фактами, либо для объяснения факта или группы фактов

Измерение - процесс присвоения чисел характеристикам изучаемых объектов согласно определенному правилу (шкале).

Зачем нужна предварительная обработка данных

Неполнота данных

- _ Отсутствие значений
- _ Место=" ", ГодРождения="n/a"
- _ "Шумы" (ошибки или аномалии) в данных
- _ Зарплата= -10000
- _ Несогласованность данных
- _ Возраст=70 и ДатаРождения="7-Окт-52"
- _ В разных записях Категория $\in \{1, 2, 3\}$ или $\{A, B, C\}$.

Почему данные содержат ошибки

Неполные данные

- _ "n/a" при сборе данных
- _ Изменение точки зрения на корректность с момента сбора данных на момент анализа данных
- _ Ошибки в программном/аппаратном обеспечении, человеческий фактор.

"Шумы" в данных

_ Ошибки в программном обеспечении сбора данных, человеческий фактор

_ Сбои при передаче данных

Несогласованность данных

_ Много различных источников данных

_ Нарушения ФЗ (например, модификация связанных данных)

Дублирование данных

Почему предварительная обработка данных важна

Нет качественных данных – нет качественных результатов их анализа.

_ Качественные решения должны быть основаны на качественных данных.

_ Хранилище данных нуждается в согласованной интеграции качественных данных.

Извлечение, очистка и трансформация данных составляют большую часть работы по построению хранилища данных.

Измерение качества данных

Общепринятая шкала качества

_ Точность

_ Полнота

_ Согласованность

_ Поддержка времени

_ Правдоподобие

_ Дополняемость

_ Интерпретируемость

_ Доступность

Другие категории

_ Привязка к контексту, репрезентативность, доступность

Цели предварительной обработки

Очистка данных (data cleaning)

_ Заполнить отсутствующие значения, сгладить зашумленные данные, определить или удалить аномалии, исправить несогласованность

Интеграция данных

_ Интеграция баз данных, кубов данных, файлов

Трансформация данных

_ Нормализация и агрегация

Редукция данных

_ Усеченное представление, гарантирующее те же или сходные результаты аналитической обработки

Дискретизация данных

_ Часть редукции – для числовых данных.

Обобщение данных

Мотивация

_ Лучше понять данные: общая тенденция, вариативность, разброс

Характеристики дисперсии

_ медиана, min, max, квантили и др.

Численные измерения, соответствующие упорядоченным интервалам

_ Анализ упорядоченных интервалов

Анализ разброса вычисленных мер

_ Перевод мер в числовые значения

_ Анализ OLAP-куба.

Измерение тенденции данных

10

□ Среднее (*mean*)

- арифметическое $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$
- взвешенное $\bar{x} = \frac{\sum_{i=1}^n w_i x_i}{\sum_{i=1}^n w_i}$

□ Медиана (*median*)

$$\text{median}(a_1, \dots, a_n) = \begin{cases} a_{[n/2]}, & n - \text{нечетное} \\ (a_{[n/2]} + a_{1+[n/2]})/2, & n - \text{четное} \end{cases}$$

□ Мода (*mode*)


- значение, которое встречается наиболее часто
 - уни- и мультимодальность
- эмпирическая формула: $\text{mean} - \text{mode} = 3 \times (\text{mean} - \text{median})$

□ Средний уровень (*midrange*): $(\max - \min)/2$

Измерение дисперсии данных

II	
----	--

- Среднеквадратичное отклонение $\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$
- Стандартное отклонение $s = \sqrt{\frac{n}{n-1} \sigma^2} = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$
- Разброс: $\max - \min$
- Ящики с усами (box-and-whiskers plot)
 - k -й перцентиль – число, отделяющее сверху $k\%$ расположенных в возрастающем порядке значений числового ряда
 - Квартили
 - $Q1$ – 25-й перцентиль
 - $Q2$ – медиана, 50-й перцентиль
 - $Q3$ – 75-й перцентиль
 - Интерквартильный размах: $IQR = Q3 - Q1$
 - Выбросы (аномалии): $1,5 * Q3$ выше $Q3$ или ниже $Q1$



Очистка данных – процедура корректировки данных, которые в каком-либо смысле не удовлетворяют определённым критериям качества, то есть содержат нарушения структуры данных, противоречия, пропуски, дубликаты, неправильные форматы и т.д.

Важность

_ Очистка данных – одна из основных проблем построения хранилищ данных

Основные цели

- _ Заполнение отсутствующих значений
- _ Определить аномалии и сгладить шумы
- _ Исправить несогласованные данные
- _ Устранить избыточность данных, вызванную интеграцией

Качество данных

Данные высокого качества

Данные содержащие критические ошибки

- невозможность загрузки в хранилище данных

Данные содержащие некритические ошибки

- аномальные значения
- пропуски
- дубликаты
- противоречия

Обработка отсутствующих данных

Игнорировать запись

Ввести вручную (часто невозможно)

Ввести автоматически

- _ значение глобальной константы
 - _ значения UNKNOWN или N/A – не всегда хорошо
- _ Ввести среднее или медиану
- _ Ввести среднее или медиану класса (классы должны быть определены)
- _ Ввести наиболее ожидаемую величину (используя моду, деревья решений или др.)

Зашумленные данные

Шум – случайное значение измеряемой переменной.

Причины некорректного значения:

- _ сбои при сборе данных
- _ сбои при вводе данных
- _ сбои при передаче данных
- _ сбои при преобразовании данных
- _ несогласованность имен данных
- _ технологические лимиты (на размер записи и др.)

Другие проблемы, требующие очистки:

- _ дублирование записей
- _ неполные данные
- _ несогласованные данные.

Обработка зашумленных данных

Биннинг (binning)

- _ Сортировка набора данных, затем разделение на равномошные поднаборы, затем сглаживание средним, медианой или граничными значениями поднабора

Регрессия.

- _ Сглаживание путем подгонки данных под регрессионную функцию.

Регрессия – зависимость среднего значения какой-либо величины от некоторой другой величины или от нескольких величин.

Кластеризация. Кластеризация – разбиение заданной выборки объектов на подмножества (кластеры) таким образом, чтобы каждый кластер состоял из схожих объектов, а объекты разных кластеров существенно отличались.

- _ Определение и удаление аномалий

Совместная инспекция человека и компьютера

- _ Определение подозрительных значений с помощью компьютера для их последующей проверки экспертом.

Биннинг

17

- Отсортированные данные:
 - 4, 8, 9, 15, 21, 21, 24, 25, 26, 28, 29, 34
- Разделение данных на группы с одинаковой частотой
 - 4, 8, 9, 15
 - 21, 21, 24, 25
 - 26, 28, 29, 34
- Сглаживание с помощью среднего арифметического группы
 - 9, 9, 9, 9
 - 23, 23, 23, 23
 - 29, 29, 29, 29
- Сглаживание с помощью граничных значений группы
 - 4, 4, 4, 15
 - 21, 21, 25, 25
 - 26, 26, 26, 34

Несогласованность данных

_ Верификация вводимых данных (проверка форматов и значений)

_ Корректировка с использованием данных по внешним ссылкам

Интеграция данных

21

- Основные проблемы
 - Идентификация сущностей
 - Как понять, что $A.CustCode = B.CustID = C.CustNo$?
 - Избыточность
 - Значение некоторого атрибута выводимо из других атрибутов
 - Несогласованность в именах атрибутов
- Пути решения проблем
 - Использование метаданных
 - Использование корреляционного анализа
 - статистический анализ взаимосвязи двух или нескольких случайных величин

Корреляционный анализ числовых данных

22

- Коэффициент корреляции Пирсона

$$r_{A,B} = \frac{\sum (A - \bar{A})(B - \bar{B})}{(n-1)\sigma_A\sigma_B} = \frac{\sum (AB) - n\bar{A}\bar{B}}{(n-1)\sigma_A\sigma_B}$$

- $r_{A,B} > 0$: положительная корреляция A и B
- $r_{A,B} < 0$: отрицательная корреляция A и B
- $r_{A,B} = 0$: независимость A и B

Корреляционный анализ нечисловых данных

23

- Тест χ^2 $\chi^2 = \sum \frac{(\text{Observed} - \text{Expected})^2}{\text{Expected}}$

- Чем больше χ^2 , тем больше связь между величинами

- Пример

	<i>Играют в шахматы</i>	НЕ играют в шахматы	ВСЕГО
<i>Любят фантастику</i>	250 (90)	200 (360)	450
НЕ любят фантастику	50 (210)	1000 (840)	1050
ВСЕГО	300	1200	1500

$$\chi^2 = \frac{(250 - 90)^2}{90} + \frac{(50 - 210)^2}{210} + \frac{(200 - 360)^2}{360} + \frac{(1000 - 840)^2}{840} = 507.93$$

Трансформация данных

24

- Сглаживание
 - удаление шумов с помощью биннинга, регрессии или кластеризации
- Агрегация
 - суммирование частичных итогов (например, месячные продажи вместо ежедневных)
- Обобщение
 - замена частных значений более общими (например, "молодой", "среднего возраста", "пожилой" вместо значения возраста)
- Нормализация
 - приведение значений к одному заданному промежутку
- Создание новых атрибутов из имеющихся
 - например, $SP.TotalSale = SP.Qty * P.Price$

Обогащение данных – процесс насыщения данных новой информацией, которая позволяет сделать их более ценными и значимыми с точки зрения решения той или иной аналитической задачи.

Внешнее обогащение предполагает привлечение дополнительной информации из внешних источников.

Внутреннее обогащение предполагает повышение информативности и значимости данных за счёт изменения и реорганизации.

Восстановление пропущенных значений

- Метод исключения некомплектных объектов. При отсутствии у ряда объектов значений каких-либо переменных некомплектные объекты удаляются из анализа. Подход легко реализуется и может быть удовлетворительным при малом числе пропусков. Однако иногда он приводит к серьезным смещениям и обычно не очень эффективен. Главный недостаток такого подхода обусловлен потерей информации при исключении неполных наблюдений.

- Методы с заполнением
- Заполнение средними.
- Заполнение с пристрастным подбором
 - Подстановка с подбором внутри групп
 - Подбор ближайшего соседа
- Заполнение с помощью регрессии
- Методы взвешивания
- Методы моделирования с помощью функции максимального правдоподобия

Квантование – процедура преобразования данных, состоящая из 2-х шагов. На первом шаге диапазон значений переменной разбивается на заданное число интервалов, каждому из которых присваивается некоторый номер (уровень квантования). На втором шаге каждое значение заменяется номером интервала квантования.

- **Равномерное (однородное) квантование.** Равномерное (однородное) квантование – преобразование, при котором диапазон значений переменной разбивается на интервалы одинаковой длины. Имеет смысл, если значения распределены равномерно по всему диапазону значений.
- **Неравномерное (неоднородное) квантование.** Неравномерное (однородное) квантование – преобразование, при котором диапазон значений переменной разбивается на интервалы различной длины (асимметричные). Имеет смысл, если в значениях нет пропусков или сгустков.

Реальные данные для анализа редко бывают хорошего качества. Необходимость в предварительной обработке при анализе данных возникает независимо от того, какие технологии и алгоритмы используются. Более того, эта задача может представлять самостоятельную ценность в областях, не имеющих непосредственного отношения к анализу данных. К задачам очистки данных относятся: заполнение пропусков, подавление аномальных значений, сглаживание, исключение дубликатов и противоречий и пр.

Термин Data Mining дословно переводится как «добыча данных» или «раскопка данных» и имеет в англоязычной среде несколько определений. Data Mining — обнаружение в «сырых» данных ранее неизвестных, нетривиальных, практически полезных и доступных интерпретации знаний, необходимых для принятия решений в различных сферах человеческой деятельности. Зависимости и шаблоны, найденные в процессе применения методов Data Mining, должны быть нетривиальными и ранее неизвестными, например, сведения о средних продажах таковыми не являются. Знания должны описывать новые связи между свойствами, предсказывать значения одних признаков на основе других.

Зачем нужна предварительная обработка?

Данные в реальном мире, как правило,

- Неполные: отсутствие определенных атрибутов или их значений, представляющих интерес, или содержащие только совокупные данные.
- Содержат шум: в значениях присутствуют ошибки или выбросы.
- Несогласованные: содержат несоответствия в кодах или именах.

Задачи предварительной обработки данных:

- Очистка данных: восполнение пропущенных значений, обнаружение и удаление искаженных данных и выбросов.
 - Интеграция данных: использование нескольких баз данных, кубов данных или файлов.
 - Преобразование данных: нормализация и агрегация.
 - Сокращение данных: уменьшение объема, но получение тех же или аналогичных аналитических результатов.
 - Дискретизация данных: часть сокращения данных, замена числовых атрибутов на номинальные.
 - Очистка текста: удаление внедренных символов, которые могут нарушать выравнивание данных, например внедренных символов табуляции в файле с разделителем-табуляцией, внедренных новых линий, которые могут разбивать записи, и пр.

Различные инструменты для предобработки данных можно найти на веб-сайте [Science Hunter](#).

Очистка информации в базах данных.

Далее описаны некоторые шаги предварительной обработки данных с точки зрения Data Mining.

Нормализующие преобразования.

Ортогонализация и декорреляция входных векторов.

Очистка данных

1. Заполнение пропущенных значений (атрибут или значение класса):
 - Игнорировать кортеж (некомплектный объект): обычно делается, в случае отсутствия метки класса.
 - Использование среднего значения атрибута (или номинальное значение) для заполнения недостающего значения.
 - Использование среднего значения атрибута (или номинальное значение) для всех образцов, принадлежащих к одному классу.
 - Прогнозирование недостающего значения с помощью алгоритма обучения: можно рассмотреть атрибут с отсутствующим значением как зависимую переменную и использовать алгоритм обучения (регрессионная модель, метод байеса или дерево решений), чтобы предсказать недостающее значение.
2. Определение выбросов и сглаживание зашумленных данных:
 - Биннинг (Binning) данных - это метод предварительной обработки данных, используемый для уменьшения влияния незначительных ошибок наблюдения. Исходные значения данных, которые попадают в данный небольшой интервал (bin), заменяются значением (так называемая "интервальная метка"), представляющим этот интервал, часто центральным значением. Таким образом, по сути, это форма квантования.
 - Статистический биннинг данных - способ группировки несколько более или менее непрерывных значений в меньшее количество «бункеров-bins». Например, если есть данные о группе людей, можно упорядочить их возраст на меньшее количество возрастных групп (например, группирование в одну группу каждые пять лет).
 - Сортировка значений атрибутов и их разбиение на ячейки;
 - Затем сглаживание с помощью бинов - биновая медиана или бин-границы.
 - Кластеризация: групповые значения в кластерах, а затем обнаружение и удаление выбросов (автоматическое или ручное).
 - Регрессия: подгонка данных к регрессионным функциям.
3. Исправить непоследовательные данные: использовать информацию домена или экспертное решение.

Восстановление отсутствующих данных.

Подавляющее большинство методов обработки и анализа данных работают только с полными данными. На практике очень часто встречаются ситуации, когда какая-либо часть данных отсутствует. Для того чтобы иметь возможность обрабатывать такие данные, необходимо восстановить отсутствующие. Существуют различные подходы к решению этой задачи. Большинство методов позволяют получить значения пропущенных данных исходя из принципа их

максимальной похожести на полные имеющиеся данные. При работе с пропущенными значениями лучше сначала определить причину их появления в данных, что поможет решить проблему. Наиболее используемые методы обработки пропущенных значений:

1. Удаление — удаление записей с пропущенными значениями.
2. Фиктивная подстановка — замена пропущенных значений фиктивными, например подстановка значения `unknown` (неизвестно) вместо категориальных или значения 0 вместо чисел.
3. Подстановка среднего значения — пропущенные числовые данные можно заменить средним значением.
4. Подстановка часто используемого элемента — пропущенные категориальные значения можно заменить наиболее часто используемым элементом.
5. Подстановка по регрессии — использование регрессионной модели для замены пропущенных значений регрессионными данными.
6. Использование статистических методов.