

Лекция. Несбалансированная классификация. Детектирование аномалий и многоклассовая классификация

- Что такое задача несбалансированной классификации
- Какие метрики подходят для оценки качества в таких задачах
- Как работать с несбалансированными классами

Введение

Задача классификации называется несбалансированной, когда для одного класса в выборке существенно меньше примеров (в 5 раз и более), чем для другого. Такие задачи встречаются очень часто. Например:

- Задача кредитного скоринга
- Предсказание поломки оборудования
- Отклик на рекламу кредита
- Выявление мошеннических операций

Разберем поподробнее откликовую модель на рекламу банковских продуктов. Как правило, рекламная кампания рассчитана на 100 000 клиентов. И только примерно 2 % клиентов совершают покупку продукта в ответ на озвученное рекламное предложение. В этой задаче наблюдается существенный дисбаланс классов.

Алгоритмы, которые минимизируют количество ошибок, могут вырождаться в классификатор, который всегда предсказывает мажоритарный класс. Поэтому нужно аккуратно следить, чтобы такого не произошло, выбирая правильные метрики для оценки качества модели и правильные модели.

Давайте посмотрим, какие существуют подходы к работе с дисбалансом классов и какие метрики лучше подходят для этой задачи.

Метрики

1. Ассигасу — точность

Определенно **неподходящая метрика** для оценки качества при дисбалансе классов. Это легко видно на следующем примере. Пусть соотношение нулей и единиц у нас 99 к 1. Тогда качество константной модели, которая будет всегда предсказывать 0, будет равно 0,99. Качество модели, которая правильно угадает все единицы и для 1% ошибочно классифицирует 0 как 1, будет иметь точно такое же качество. Хотя вторая модель явно полезнее.


2. Precision (точность), Recall (полнота), F1 score

Наиболее подходящие метрики для подобных задач, поскольку их легко связать с понятиями, которыми пользуется бизнес для принятия решений.


3. ROC AUC и PR AUC

Данные метрики предназначены для оценки предсказаний модели в виде вероятностей (т. е. полученных методом **predict_proba**). Иногда удобнее в начале экспериментов работать с вероятностями и оценивать качество ранжирования в целом. А затем отдельно подбирать порог бинаризации, пользуясь метриками Precision/Recall.

Обе метрики адекватно работают с дисбалансом классов. Тем не менее, если дисбаланс очень сильный, чувствительность метрики ROC AUC сильно падает. В таких случаях предпочтительно пользоваться PR AUC.



— Gradient boosting (Random Forest)
 - - - Logistic regression



— Gradient boosting (Random Forest),
 PR AUC = 0,395
 - - - Logistic regression, PR AUC = 0,226

Пример метрик ROC_AUC и PR_AUC Как учитывать дисбаланс классов

Ребалансировка данных

Можно «выровнять» обучающую выборку одним из следующих способов:

Undersampling

В этом методе необходимо уменьшить количество объектов большего класса. То есть берем сэмпл объектов большего класса по величине такой же, как размер объектов меньшего класса.




Oversampling

Здесь мы пытаемся увеличить выборку объектов меньшего класса: просто сэмплируем из него объекты, чтобы он по численности сравнялся с количеством объектов большего класса. При этом можно не просто сэмплировать объекты случайно, а использовать специальные алгоритмы. Давайте рассмотрим один из них:



SMOTE (Synthetic Minority Oversampling Technique)



В этом методе мы пытаемся создать новые объекты меньшего класса. Алгоритм здесь довольно простой: для каждого объекта меньшего класса, мы ищем k ближайших соседей меньшего класса, и на отрезке между ними случайно выбирается новый объект.

Важно! Обратите внимание, такие преобразования (все методы ребалансировки данных) применяются только к обучающей выборке. Тестовая выборка остается неизменной. Потому что качество, измеренное на измененной выборке, не будет соответствовать качеству модели на реальных данных.

Reweighting

Можно назначить объектам малого класса больший вес в функционале ошибки. То есть за ошибку на малом классе штраф будет выше, чем за ошибку на большем. В `sklearn` многие классификаторы умеют перевзвешивать объекты, надо просто задать параметр `class_weight`.

Ничего не делать

Это тоже неплохой способ справляться с дисбалансом классов. Несмотря на сложности, многие алгоритмы показывают хорошее качество на несбалансированных выборках.

Что нужно контролировать, когда выборка несбалансированная

- Использовать стратифицированный контроль

Разбивать выборку на обучающую и тестовую, сохраняя соотношение классов в каждом датасете (фолде, если речь о кросс-валидации). В `sklearn` для этого есть встроенный метод: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html.

- Контролировать пороги

Для таких задач критически важно получать от алгоритма вероятности, а не метки классов (пользоваться методом `predict_proba` вместо `predict`) и подбирать порог классификации исходя из требований к метрикам.

- Пользоваться правильными метриками для оценки качества модели

Выводы:

1. Если вы столкнулись с задачей с дисбалансом классов, самое главное — учесть это в постановке задачи: выбрать подходящие метрики оценки качества модели и правильно валидировать модель
2. Можно попробовать применить методы «выравнивания» балансов классов, но такие техники вносят меньший вклад в качество модели, чем п. 1

Многоклассовая классификация

О чем мы поговорим:

- Постановка задачи
- Как данная задача решается в разных классах моделей
- Как оценивать качество моделей для задачи многоклассовой классификации

Постановка задачи

Пусть у нас есть k классов. Каждый объект выборки относится только к одному классу. Необходимо научиться предсказывать эти классы. Самый каноничный пример такой задачи — Ирисы Фишера: здесь необходимо по замерам листьев и лепестков определить один из трех видов ириса (Ирис щетинистый (*Iris setosa*), Ирис виргинский (*Iris virginica*) и Ирис разноцветный (*Iris versicolor*)).

Пример решающего дерева для классификации ирисов

Классифицируем три вида ирисов: *setosa*, *versicolor* и *virginica*.

Признаки: длина и ширина лепестка и стебля



Iris Versicolor



Iris Setosa



Iris Virginia

Также задачами многоклассовой классификации являются:

- Определение тематики запроса обращения в техподдержку
- Определение объекта, изображенного на фотографии
- Определение банковского продукта, который стоит предложить клиенту




Рисунок 1. Ирисы Фишера, классификация на три сорта по признакам растения

Методы решения Линейные модели

Разберем две основные стратегии разложения мультиклассовой задачи на несколько задач бинарной классификации. Пусть мы хотим построить модель, которая определяет, к какому из k классов принадлежит объект:

- Стратегия **One vs One** (каждый против каждого)

Для каждой пары классов (i, j) мы строим бинарную модель, которую обучаем разделять эти классы. Модель должна возвращать метки классов — i или j . Данная модель будет использоваться для обучения не всю выборку, а только объекты классов i и j . У нас получится $k(k - 1) / 2$ моделей. Чтобы определить, к какому классу принадлежит новый объект, мы подаем его на вход каждой из наших обученных моделей. Объекту присваивается класс, за который проголосовало большинство моделей.

- Стратегия **One vs All** (один против всех)

Здесь для каждого класса i мы строим бинарную модель, которая учится отделять объекты этого класса от всех остальных объектов. Модель должна возвращать вероятности принадлежности объекта к классу i . В каждой модели будет использоваться максимальное количество данных, но каждая такая

бинарная задача, скорее всего, будет несбалансированной по количеству объектов в группах.

У нас получится k бинарных моделей. Чтобы определить, к какому классу принадлежит новый объект, мы подаем его на вход каждой из наших обученных моделей. Объекту присваивается класс, на который была обучена самая «уверенная» модель.




Рисунок 2. Две стратегии обучения задачи мультиклассовой классификации: **One vs One** (левый рисунок), **One vs All** (правый рисунок)

Решающие деревья

В решающих деревьях для многоклассовой классификации используются те же критерии ветвления, что и для бинарной:

- Критерий информативности Джини
- Энтропийный критерий информативности

Нейронные сети

Для решения этой задачи нам подойдет нейронная сеть произвольной архитектуры, которая на выход выдает k чисел с вероятностями принадлежности объекта к каждому классу. Чтобы этого добиться, в качестве последнего слоя нейросети берут функцию softmax.

Softmax — это обобщение логистической функции для многомерного случая. Функция преобразует вектор z размерности K в вектор σ той же размерности, где каждая координата $\sigma(z)_i$ полученного вектора представлена вещественным числом в интервале $[0, 1]$, и сумма координат равна 1.

$$\sigma(z)_i = \frac{e^{z_i}}{\sum_{k=1}^K e^{z_k}}$$

Координаты σ_i вычисляются следующим образом:

Метрики

При выборе метрики обычно используют следующую эвристику:

Если классов намного больше 10, то смотрят на метрику **accuracy**.

Если классов меньше 10, то смотрят на стандартные метрики, используя одну из следующих двух стратегий.

Для каждого класса можно построить confusion matrix по принципу one vs all (например, с помощью `sklearn.metrics.confusion_matrix`)

А затем выбрать одну из двух стратегий:

1. Микроусреднение

Мы усредняем все confusion matrix для классов и на основании полученной матрицы рассчитываем привычные нам метрики: accuracy, precision, recall etc. При дисбалансе классов такой подход будет уделять меньше внимания классам, которые представлены небольшим количеством объектов.

2. Макроусреднение

Здесь мы сначала считаем метрики для каждого класса и затем усредняем

их. Пример:

$$\text{precision_macro} = \frac{\sum_i \text{precision}(i)}{k}$$

При макроусреднении каждый класс вносит одинаковый вклад в качество независимо от его численности.

В sklearn тип усреднения в метриках можно задать с помощью параметра **average**.

Детектирование аномалий

О чем мы поговорим:

- Постановка задачи детектирования аномалий
- Вероятностный подход
- Методы машинного обучения для детектирования аномалий. Isolation Forest.

Введение

Задача поиска аномалий — это задача, где нам нужно найти объекты, которые не похожи на большинство объектов из обучающей выборки. При этом примеров аномалий либо нет вообще, либо очень мало.

Примеры задач поиска аномалий:

- Выявление мошеннических операций
- Обнаружение вторжений
- Поломка оборудования
- Сейсмология

При этом следует разделять два направления:

Детектирование выбросов (outlier detection) — мы видели такие объекты в обучающей выборке, и они размечены.

Поиск новизны (novelty detection) — раньше нам такие объекты не встречались.

Отсюда у нас может получиться 3 различные постановки задачи:

- Supervised

У нас в обучающей выборке есть размеченные примеры аномалий, и задачу можно рассматривать как классификацию с дисбалансом классов.

- Semi-supervised

У нас в обучающей выборке есть размеченные примеры аномалий, но какие-то объекты могли быть пропущены. Например, в данных работы какого-то прибора эксперт указал нам на моменты поломок, но были еще какие-то поломки, о которых он не знал. То есть он разметил не все поломки.

- Unsupervised

Это когда размеченных примеров аномалий в обучающей выборке у нас нет.

Рассмотрим, какие подходы существуют для решения данной задачи.

Вероятностный подход

В данном подходе предлагается считать, что аномалия происходит из распределения, отличного от того, с помощью которого была сгенерирована обучающая выборка. Для этого нужно восстановить плотность выборки $p(x)$.

Есть два подхода к восстановлению плотности выборки:

Параметрический подход

Здесь мы считаем, что распределение принадлежит некоторому семейству $\{p(x | \theta), \theta \in \Theta\}$, и нужно просто подобрать параметр θ с помощью метода максимального правдоподобия: $\sum_{i=1}^l \log p(x_i | \theta) \rightarrow \max_{\theta}$

Кроме того, в качестве распределений может выступать смесь распределений.

Непараметрический подход


Здесь мы не пытаемся вводить никаких ограничений на вид распределения и используем только сами данные. С доказательством можно ознакомиться, например, вот здесь: <https://github.com/esokolov/ml-course-hse/blob/master/2019-spring/lecture-notes/lecture16-anomaly.pdf>.

Методы машинного обучения. Isolation Forest

Наиболее действенным методом для поиска аномалий является Изолирующий лес. Идея состоит в следующем:

1. Для построения ветвления в дереве выбирается случайный признак и случайный порог
2. Мы строим каждое дерево так, чтобы в листе остался только один объект
3. Оценка аномальности объекта — среднее арифметическое глубин листьев, на которые он попал

Здесь мы предполагаем, что чем сильнее объект отличается, тем раньше он будет отделен от всех остальных объектов и попадет в свой отдельный лист.



where $I_i(x)$ is the path length of x traversed in tree i

Выводы:

- Детектирование аномалий — сложная задача, требующая аккуратности в выборе подхода
- Если в обучающей выборке достаточно примеров, следует попробовать подойти к проблеме как к задаче классификации. Если примеров слишком мало/нет совсем, хорошей стартовой точкой будет IsolationForest (в целом хорошо справляется с задачей и не требует сложных настроек).