


Обучение без размеченных данных: постановки, прикладные задачи

Рассмотрим, что можно делать с данными, если у них нет разметки и целевой переменной, а извлечь какую-то информацию очень нужно.

Парадигма обучения с учителем vs парадигма обучения без учителя



Данные в задаче **обучения с учителем** (или на размеченных данных) по структуре соответствуют картинке справа.

В таблице в части столбцов — значения признаков, которые описывают объект, в отдельном столбце — значения целевой переменной. Каждая строка соответствует отдельному объекту, паре *входное описание* — *значение целевой функции*.

Задача машинного обучения в этом случае понятна: научиться по описанию объекта предсказывать значение размеченной целевой функции. В задаче регрессии целевая функция принимает значения из некоторого диапазона, в задаче классификации — из конечного набора возможных ответов, классов.

Так как у нас есть правильные ответы, то такую постановку задачи в машинном обучении называют *обучением с учителем*, который знает правильные ответы, или *обучением на размеченных данных*.



Данные в задаче **обучения без учителя** (или на неразмеченных данных) по структуре соответствуют другой картинке справа.

В таблице в части столбцов — значения признаков, которые описывают объект. Целевой переменной у нас в данных нет.


Про возможные постановки задач машинного обучения для таких данных мы и будем говорить в этом лонгриде. Они встречаются реже, чем задачи обучения с учителем. Решать и понимать, насколько хорошее получилось решение, в этом случае сложнее.

Так как у нас нет правильных ответов, то такую постановку задачи в машинном обучении называют *обучением без учителя*, или *обучением на неразмеченных данных*.

Кроме задачи обучения на размеченных и неразмеченных данных еще рассматривают задачи на частично размеченных данных, когда для части объектов ответы есть, а для части нет. Но на практике они встречаются не очень часто, поэтому в этом курсе мы их рассматривать не будем.

Восстановление распределения данных

Часто можно думать про задачу обучения без учителя как про задачу восстановления распределения данных: понимание того, как объекты распределены в пространстве признаков, какие наиболее характерные значения у них есть, где объектов мало, а где они лежат плотными кучками.



Пример полученного с помощью машинного обучения распределения данных можно увидеть на рисунке. Синие точки — значения двух признаков из обучающей выборки. Закрашенные синим разной насыщенности области — восстановленное распределение. Чем более интенсивный цвет, тем вероятнее, что в эту область попадет новая точка. Если у нас есть такая модель, то для новой точки мы можем сказать, насколько она вероятна в рамках существующего распределения данных. Если вероятность встретить точку в этом месте мала, то такая точка может быть *аномалией* или *выбросом*, и нужно аккуратно с ней работать.

Другой пример задачи машинного обучения на неразмеченных данных — кластеризация. Мы разбиваем все точки на кластеры похожих. На рисунке 2 мы выделили в данных два кластера, ограниченных зеленой и оранжевой линиями. Теперь для новой точки мы знаем, к какому кластеру она принадлежит и, следовательно, на какие точки из исходной выборки похожа.

Формальная постановка задачи кластеризации.

Пусть X - множество объектов, Y - — множество номеров (имен, меток) кластеров. Задана функция расстояния между объектами $\rho(x, x')$. Имеется конечная обучающая выборка объектов $X^m = \{x_1, \dots, x_m\} \subset X$. Требуется разбить выборку на непересекающиеся подмножества, называемые *кластерами*, так, чтобы каждый кластер состоял из объектов,

близких по метрике ρ , а объекты разных кластеров существенно отличались. При этом каждому объекту $x_i \in X^m$ приписывается номер кластера y_i .

Алгоритм кластеризации — это функция $\alpha: X \rightarrow Y$, которая любому объекту $x \in X$ ставит в соответствие номер кластера $y \in Y$. Множество Y в некоторых случаях известно заранее, однако чаще ставится задача определить оптимальное число кластеров, с точки зрения того или иного *критерия качества* кластеризации.

Зачем нужна кластеризация данных — разберем дальше.

Примеры задач кластеризации

Начнем с научной **задачи кластеризации небесных тел**: мы измеряем для небесных тел силу излучения на семи разных частотах. Проведя кластеризацию, можно выделить основные типы небесных тел. Когда на небе появится новый объект, мы сразу определим, что это звезда. Если какие-то объекты не попали ни в один из кластеров, нужно на них посмотреть внимательнее.

Ближе к приложениям — **задача кластеризации документов** или новостей. Каждый день в интернете публикуются тысячи новостей, причем часто про одно и то же рассказывают на разных сайтах. «Яндекс.Новости» кластеризует описания одного события с разных сайтов в сюжеты, чтобы пользователю было проще в них ориентироваться. Никакой разметки в этой задаче сделать не получится, потому что новые сюжеты появляются каждую минуту. Нужно использовать алгоритмы кластеризации, которые могут решать эту задачу без разметки.

Похожие задачи часто встречаются в бизнесе:

- **Сегментация пользователей**: пользователи в каждом кластере должны быть похожи друг на друга, а в соседних — отличаться. Тогда, посмотрев на характеристики пользователей в каждом кластере, мы сможем выбрать наиболее подходящий кластер целевой аудитории для новой маркетинговой кампании
- **Детектирование аномалий**: ищем те транзакции, которые не попадают ни в один из кластеров. Такие аномальные транзакции могут быть мошенническими
- **Подготовить данные для машинного обучения** (разбить на группы): если пользователи в группах более однородны, для каждой группы можно обучить свою модель машинного обучения, которая будет более интерпретируемой и точной
- **Аналитика доступных данных**: проведя кластеризацию, мы поймем, с какими клиентами мы работаем, что общее для каждого кластера пользователей, а чем они отличаются

Постановка задачи кластеризации

Можно описать задачу кластеризации как разбиение объектов на однородные группы. В результате обучения модель кластеризации может для нового объекта определить номер кластера, к которому этот объект с ее точки зрения принадлежит.

Пример работы алгоритма кластеризации — в таблице ниже. Меток кластера в обучающей выборке не было, алгоритм сам придумал правило для разбиения объектов на кластеры.

Входные признаки				Результат кластеризации
x_1 возраст	x_2 пол	x_3 доход за последний месяц	x_4 количество членов семьи	Метка кластера
25	1	70000	0	1
32	0	63000	1	2
29	0	81000	0	1
44	0	54000	2	2

У нас должен выполняться *внутренний критерий качества кластеризации*: объекты внутри одного кластера похожи друг на друга.

Кроме того, должен выполняться *внешний критерий качества кластеризации*: объекты из разных кластеров отличаются друг от друга.

Метрики качества кластеризации — обычно некоторая комбинация этих двух критериев, и их пытаются формализовать тем или иным образом.

Однако так как точного критерия близости у нас нет, с точки зрения и математики, и бизнеса, задача поставлена не очень хорошо. Поэтому трудно понять, насколько хорошую кластеризацию мы получили. Можно сделать это косвенно, посмотрев на качество решения бизнес-задачи, которая использует полученную кластеризацию.


Другие постановки задачи кластеризации

Выделяют другие постановки задачи кластеризации: мягкую кластеризацию и иерархическую кластеризацию.

Кластеризация может быть не жесткой (hard), а **мягкой** (soft). В этом случае результатом работы модели кластеризации будет не жесткая метка кластера для каждого объекта, а набор вероятностей принадлежности к каждому из классов. Как и для задачи классификации, легко перейти от мягкой к жесткой кластеризации, взяв в качестве метки кластера индекс кластера с максимальной вероятностью. Пример работы алгоритма мягкой кластеризации приведен в таблице ниже.

Входные признаки				Мягкая кластеризация		Жесткая кластеризация
x_1 возраст	x_2 пол	x_3 доход за последний месяц	x_4 количество членов семьи	вероятность принадлежности к первому кластеру	вероятность принадлежности ко второму кластеру	жесткая метка кластера
25	1	70000	0	0,82	0,18	1
32	0	63000	1	0,24	0,76	2
29	0	81000	0	0,87	0,13	1
44	0	54000	2	0,11	0,89	2

Другой способ создать более гибкую модель кластеризации — иерархическая кластеризация. В этом случае результатом работы алгоритма кластеризации будет дерево, похожее на изображенное ниже. Для того чтобы получить из такого дерева кластеризацию, мы выбираем уровень, изображенный на рисунке оранжевой линией. После этого идем от пересечений оранжевой линии с черной вниз, получая в данном примере четыре кластера. Если мы сделаем разбиение выше или ниже, получим больше или меньше кластеров, более релевантных решаемой задаче бизнеса.



Методы кластеризации: метод k-средних, метод гауссовских смесей,

DBSCAN

Внешние и внутренние метрики качества: коэффициент Джаккарда,

коэффициент силуэта

Метрики качества в задаче кластеризации

Для классификации и обучения с учителем имеется множество различных метрик качества модели: точность, полнота, доля правильных

классификаций, ROC AUC. Так как у нас есть правильные ответы, на тестовой выборке мы сравниваем полученные моделью ответы с правильными и получаем оценку качества как меру несовпадения правильных и предсказанных моделью ответов.

Для кластеризации возникает вопрос: как оценить ее качество, если у нас нет разметки или если имеющаяся разметка недостаточно полно отражает желаемое разбиение данных?

Необходимы метрики для сравнения алгоритмов кластеризации и двух полученных множеств кластеров. Различают *внутренние и внешние метрики качества кластеризации* (по смыслу внешние и внутренние метрики отличаются от внешних и внутренних критериев).

Внешняя метрика сравнивает полученные метки кластеров с метками, которые мы получили из какого-то другого источника.

В качестве примера внешней метрики будем использовать **индекс Джаккарда**.

Пусть у нас есть истинные метки классов и разбиение на кластеры, полученное с помощью алгоритма кластеризации. Тогда для пары точек из выборки наблюдается одна из четырех ситуаций:

1. Две точки лежат в одном кластере, но метки классов у них разные
2. Две точки лежат в одном кластере, и метки классов у них одинаковые
3. Две точки лежат в разных кластерах, и метки классов у них разные
4. Две точки лежат в разных кластерах, но метки классов у них одинаковые

Ситуации 1 и 4 соответствуют неадекватной кластеризации с точки истинной разметки, ситуации 2 и 3 говорят о соответствии полученной кластеризации и истинной разметки.

Пусть количество пар для каждой ситуации соответственно A_1 , A_2 , A_3 , A_4 . Тогда индекс Джаккарда равен $J = A_2 / (A_2 + A_4 + A_1)$.

В идеальном мире A_1 и A_4 равны нулю, и индекс Джаккарда равен своему максимальному значению — 1. В худшем случае A_2 равно нулю, и индекс Джаккарда равен своему минимальному значению — 0. В реальности мы наблюдаем промежуточную ситуацию: чем больше индекс Джаккарда, тем лучше соответствие между заданной «истинной» разметкой и полученной кластеризацией.

Читателю может показаться, что мы забыли про A_3 , и он прав. Но количество A_3 про то, что объекты из разных кластеров должны сильно отличаться, а в индексе Джаккарда мы смотрим на то, насколько похожи точки внутри одного кластера. Поэтому A_3 и не входит в формулу.

У индекса Джаккарда есть и другая интерпретация: насколько сильно пересекаются множества одинаковых пар с точки зрения истинной разметки и с точки зрения алгоритма кластеризации.

Обычно истинной разметки у нас нет. Поэтому используют внутренние метрики.

Внутренняя метрика качества кластеризации не использует никакой дополнительной информации.

Посмотрим на типичную внешнюю метрику — **коэффициент силуэта**.

Сначала научимся считать коэффициент силуэта для одной точки i .

Посчитаем среднее расстояние от нее до всех точек этого же кластера $a(i)$, посчитаем среднее расстояние от этой же точки до точек из других кластеров $b(i)$. Чем меньше $a(i)$, тем лучше; чем больше $b(i)$, тем лучше.

Поэтому коэффициент силуэта считается по следующей формуле:


$$s(i) = (b(i) - a(i)) / \max(a(i), b(i)).$$

Если $s(i)$ больше нуля, то в среднем точки того же кластера ближе, чем точки из других кластеров, потому что $b(i) > a(i)$. Если $s(i)$ меньше нуля, то ситуация обратная, и эта точка кластеризовалась не очень удачно. Для нормировки мы делим разность между $b(i)$ и $a(i)$ на максимум из этой пары и получаем нормированную разность. Если она близка к 1, все хорошо; если близка к -1 , все плохо.

Усреднив коэффициент силуэта по всем точкам обучающей выборки, получим общую характеристику качества кластеризации. Так как каждое из значений от -1 до 1, то и их среднее будет из этого диапазона.

Коэффициент силуэта близкий к 1 соответствует высокому качеству кластеризации, коэффициент силуэта близкий к -1 — низкому.

Как и многие другие метрики, связанные с расстояниями между объектами, коэффициент силуэта работает, если расстояния отражают похожесть объектов друг с другом. Поэтому в больших размерностях, когда входных признаков мало, в силу проклятия размерности расстояния слабо отражают похожесть объектов. Следовательно, и коэффициент силуэта плохо применим.



Кроме выбора алгоритма кластеризации значения метрики качества могут использоваться для *выбора числа кластеров*. Если с какого-то количества кластеров метрика перестает падать, значит в данных именно такое истинное их число. Так как форма кривой обычно похожа на две прямые с таким изгибом (как рука), а метрика перестает уменьшаться в ее сгибе, такой критерий называют *критерием локтя* для выбора числа кластеров.